

10分钟拆解大语言模型黑箱

目录

CONTENTS

01 LLM的本质

02 LLM的运作机制

03 涌现能力

04 LLM的三大“拿手好戏”

05 理性应用

06 总结


PART 01

LLM的本质

自监督学习

自监督学习概述

自监督学习是一种强大的机器学习技术，通过自动从数据中发现规律和模式，实现了对复杂系统的精准描述和预测。



海量数据处理

自监督学习能够轻松地应对海量数据的挑战，从中提取出关键的信息和模式，为后续的决策和行动提供有力支持。

规律与模式识别

自监督学习的核心在于识别和提取数据中的规律和模式，无论是简单的还是复杂的模式，它都能敏锐地捕捉到。



缺乏真实体验



LLM的局限


LLM作为一个语言模型，确实表现出色，但缺乏真实世界的体验和互动，使其在某些方面存在局限性。

真实体验的重要性

尽管LLM可以生成流畅的文本，但它无法像人类那样真正理解语言的含义和语境，这限制了其在某些任务上的表现。

与人类的差异

LLM可以模仿人类的写作风格，但无法像人类那样理解和感受语言的魅力，这使其在某些方面与人类存在显著差异。



数据洪流≠真智能



数据洪流

45TB的文本数据，相当于8万亿词，一个人需要数百年不眠不休才能读完，但这只是信息的堆砌，并非智慧的涌现。

LLM的局限性

虽然LLM能够模仿文字套路，甚至写出诗歌，但缺乏人类的因果逻辑和真实世界的感官经验。

PART 02

LLM的运作机制

一个强大的模型

模型的数据


海量优质的数据是训练强大模型的关键，模型的“广度”源于其“食谱”的多样性，需要杂食性的精神食粮。

架构是心脏


比模型规模更重要的是架构，Transformer架构是模型的核心，赋予模型“上帝视角”，能同时关注句中所有词，动态判断关联性。

模型消歧 “Bank”

通过注意力机制，模型能够根据上下文动态调整注意力权重，实现准确的词义消歧，消歧“Bank”时，根据上下文调整注意力权重。



一个强大的模型



训练是过程

模型训练分为预训练和微调两个主要阶段，预训练通过巨型填词游戏学习语言统计规律，微调则利用特定领域数据调整模型参数。



涌现能力

当模型规模大到一定程度时，会突然展现出未经明确教授的新能力，如简单推理、理解幽默，涌现能力基础能力是模式识别。



LLM三大能力

模式识别与信息处理、内容生成与创意辅助、智能交互与对话，涵盖文本分类、情感分析、信息提取、撰写文章、虚拟助理等。

一个强大的模型


识别与处理

模式识别与信息处理是LLM的基础能力之一，能够自动识别和提取文本中的关键信息，但存在“幻觉”问题，需交叉验证。




常识与时效

LLM缺乏真实世界理解和时效性，无法体验物理常识和感官体验，知识停留在训练数据截止日期，对于最新事件和信息一无所知。



偏见与伦理阴影

训练数据包含社会偏见，LLM会吸收并放大这些偏见，需设置审核机制、对抗样本与价值观对齐，以避免偏见和伦理问题。



一个强大的模型



理性应用

理性应用LLM是关键，明确其适合和不适合的场景，如重复性内容生成、关键决策、创意工作等，并避免在需要深度专业判断和担责的工作上使用。





拥抱AI

拥抱AI，保持清醒，理解LLM的本质、炼成与边界，在兴奋与警惕间找到平衡，才能充分发挥其威力。

架构是Transformer 心脏

Transformer 心脏

Transformer架构是LLM的核心，其特点在于使用注意力机制，赋予模型“上帝视角”，能够同时关注句中所有词，并动态判断它们之间的关联性。




注意力机制

注意力机制是Transformer的核心，通过计算注意力权重，使模型能够关注到最重要的信息，而忽略掉不重要的部分，从而提高处理效率。

动态判断关联性

在Transformer中，注意力机制是动态判断的，根据输入数据的不同，模型能够自动调整注意力权重，关注到最相关的部分。



案例消歧 “Bank”



注意力的权重

在“Bank”消歧案例中，上下文“利率”、“存款”与“河流”、“树木”分别引发了不同的注意力权重偏向。

权重偏向

在“利率”、“存款”的上下文中，模型将更多的注意力权重偏向于“银行”，而在“河流”、“树木”的上下文中则偏向于“河岸”。

更高权重

在多个上下文的共同作用下，模型能够更准确地理解“Bank”一词在特定语境中的含义，并给予相应的权重。

PART 03

涌现能力

基础能力



模式识别

模式识别是AI的基础能力，通过算法从数据中自动提取特征，对复杂模式进行精准分类和识别。



信息处理

内容生成与创意辅助，智能交互与对话，文本分类、情感分析、信息提取、高质量翻译等。



创意辅助

撰写文章、邮件、代码，以及头脑风暴；智能客服、虚拟助理、个性化教育辅导等。

未知能力

常识与时效

模型缺乏真实世界理解，知识存在“时效性”，没有物理常识和感官体验，只能复述“血是铁锈味”，却永远无法真正体验。

偏见与伦理阴影

训练数据包含社会偏见，模型可能放大这些偏见；需设置审核机制、对抗样本与价值观对齐。



PART 04

LLM的三大“拿手好戏”

模式识别与信息处理

认知缺口

模型缺乏真实世界理解，知识存在“时效性”，没有物理常识和感官体验，只能复述“血是铁锈味”，却永远无法真正体验。

“幻觉”问题

模型会一本正经地胡说八道，因为它是在预测下一个最可能的词，而非检索事实数据库，它编造信息时，态度可能比你更肯定。

偏见与伦理阴影


训练数据包含偏见，模型会吸收并放大这些偏见，需设置审核机制、对抗样本与价值观对齐，以避免偏见放大。

理性应用

AI擅长重复性工作、创意原型设计、实时信息处理等；不适合100%准确决策、深度专业判断等。需明确场景，合理应用。

拥抱 AI

LLM是威力巨大的杠杆，却非万能神器；理解其本质、炼成与边界，才能在兴奋与警惕间找到平衡。



内容生成与创意辅助

工作效率提升

AI模型可以自动撰写文章、邮件、代码等，大幅提高创作效率，让人类有更多时间专注于创意和灵感。

质量优化

AI模型具备语言生成和文本分析能力，可自动润色文本，修正语法错误，提升内容质量，确保输出更加专业和准确。



创意激发

通过机器学习算法，AI模型能够生成多种创意方案，为人类提供灵感和辅助，帮助人类更好地实现创意目标。

素材搜集

在创作过程中，AI模型能够帮助搜集相关素材和信息，提供有力支持，让人类能够更轻松地完成创作任务。

智能交互与对话



24小时客服

智能客服提供全天候服务，即时回应客户咨询，确保问题迅速得到解决，提升客户满意度。

虚拟助手

虚拟助理安排日程、提醒事项、购买商品等，智能化管理日常生活，为用户节省时间，提高生活质量。

个性化教育

个性化教育辅导根据学生的学习进度和需求，智能推荐学习资源，提供定制化教学方案，助力学生高效学习。

PART 05

理性应用

适合的场景

01 内容生成与决策

LLM擅长处理大量重复性内容生成，如营销文案，同时能迅速作出需要高度准确的决策，如医疗诊断，展现其在信息处理和判断上的高效与精准。

02 创意与实时信息


创意工作中，LLM加速原型设计，如UI描述；实时信息任务，如新闻报道，凸显其在快速响应和获取最新资讯方面的强大能力。

03 代码辅助

繁琐的代码辅助与检查，LLM能够高效完成；同时，在容错率较高的信息处理与对话中，表现卓越，展现其在复杂任务处理中的灵活与可靠。

04 金融风险与交易

尽管在涉及重大金融风险的自动化交易中表现稳健，但仍需谨慎使用，确保风险管理措施到位，体现人机协同在关键任务中的不可或缺性。



不适合的场景

判断与担责

LLM在需要深度专业判断和担责的工作场景中表现有限，如法官判案，这类工作往往要求高度的专业知识和责任感，超出当前技术范围。

自动化交易风险

涉及重大金融风险的自动化交易虽可由LLM部分承担，但仍需人类监督与决策支持，避免因模型局限导致不可预测的风险。

清醒认识AI

拥抱AI技术的强大潜力时，保持清醒至关重要。LLM作为威力巨大的杠杆，并非万能神器，其应用需遵循人机协同的原则。

工具与边界

理解LLM的本质、炼成与边界，是在兴奋与警惕间找到平衡的关键。这有助于我们更好地利用这一技术，推动社会进步与发展。



PART 06

总结

总结



LLM的三大“拿手好戏”



模式识别与信息处理、内容生成与创意辅助、智能交互与对话，涵盖文本分类、情感分析、信息提取、高质翻译等能力。

LLM的“脏活累活”



撰写文章、邮件、代码，以及头脑风暴等任务，LLM能够高效准确地完成，充分展现其强大的文字处理和创意生成能力。

LLM的“拿手绝活”



智能客服、虚拟助理、个性化教育辅导等，LLM提供便捷、个性化的交互体验，深刻改变着人们的生活和工作方式。

总结



LLM的“能力陷阱”与“认知缺口”

模型会一本正经地胡说八道，因为它缺乏真实世界理解和时效性，知识停留在训练数据截止日期，无法应对最新事件和信息。


LLM的“偏见与伦理阴影”

训练数据包含社会偏见，LLM可能放大这些偏见，需设置审核机制、对抗样本与价值观对齐，避免偏见在生成内容中放大。



理性应用

适用于重复性内容生成、需要快速原型设计的创意工作等场景；不适用于需要100%准确性的关键决策、涉及重大金融风险的自动化交易等场景。



THANKS

感谢观看