

The background of the slide is a light gray technical drawing or blueprint. It features a grid of lines, with some lines forming a diamond shape in the center. There are various geometric shapes, including circles and squares, and some areas are shaded with diagonal lines. The overall style is that of a technical sketch or a blueprint.

大模型应用架构：从提示到系统

解锁 AI 应用的真正潜力

掌握高级AI架构意味着什么？

职业价值

提示词工程师

30-60K

Senior GenAI Specialist
Solutions Architect

From \$138,200 a year

Director, Generative AI Platform -
Agents and Tooling

\$85,500-\$128,300 a year

市场需求巨大，薪资待遇优厚。但这仅仅是开始。

商业影响

效率提升

30%

成本降低


30%

业绩提升

至少 30%

通过系统化的AI应用，企业正在实现指数级增长。

基础交互的局限：一个与现实世界脱节的“黑箱”




- **非实时性**：模型知识截止于训练日期，无法获取最新信息。
- **缺乏外部能力**：无法查询天气、股价、执行订单或访问任何外部API。
- **数据隐私**：无法访问私有、未公开的企业知识库或数据库。

仅靠对话，我们无法构建出真正强大、能解决复杂现实问题的应用程序。

案例研究：一个“超级IP”如何在100天内实现爆发式增长

3月13日：第一次拍摄 4月3日：第1条视频，破1.5万播放 5月16日：破10万+播放 6月14日：破100万+播放 7月7日：破500万+播放



这样的成果，仅仅是通过巧妙的提示词实现的吗？不。这是系统化方法论的胜利。

揭秘背后：系统化方法论第一步 - IP定位

在写下第一个提示词之前，先完成最关键的分析工作。

1. 用户画像分析

深入理解目标用户的核心痛点。

用户痛点分析表	
痛点问题	痛点描述
	无法有效整合...
	缺乏自动化...
	缺乏自动化...
	缺乏自动化...

2. IP定位分析

基于用户痛点，明确IP的商业、人设和内容定位。

IP定位分析表	
商业定位：	短视频+直播
人设定位：	有爱的企业老板
内容定位：	切入点：产品

所有成功的提示，都源于对这些战略定位的深刻洞察。


系统化方法论第二步 - 拆解对标

将行业最佳实践解构成可执行的数据标签，用数据指导创作。



关键动作：爆款拆解与标签生成


分析竞品的选题、文案、视频结构、用户行为等，将定性分析转化为结构化的数据标签。



精准的数据是生成高质量、高命中率内容的前提。

系统化方法论第三步 - 创作爆款

此时，提示词不再是模糊的请求，而是基于深度分析的精确指令。



指令示例：生成“餐饮30年”选题


了解，你做餐饮30年。以下是我为你量身生成的10个 **【爆款标题】**：

1. 《做餐饮30年，我发现的行业秘密是什么？》
2. 《做餐饮30年，最应该避开的坑有哪些？》

...

看似简单的prompt，背后是整个商业分析体系的浓缩。模板本身没有用，系统才有。


解锁新能力：为大模型连接真实世界




- **Function Calling:** 一种机制，允许大模型在需要时，请求应用程序执行预先定义好的“工具”（函数），以获取外部信息或执行特定操作。
- 这解决了LLM无法访问实时数据、外部API和私有知识库的核心问题。

Function Calling 流程解析 (1/2): 模型如何请求帮助

场景: 用户提问: “今天长沙天气怎么样?”



Function Calling 流程解析（2/2）：应用如何完成闭环



代码实现：定义工具与双重调用

定义你的工具

```
tools = [  
    {  
        "type": "function",  
        "function": {  
            "name": "get_city_weather",  
            "description": "获取指定城市的天气",  
            "parameters": { ... }  
        }  
    }  
]
```

通过一个类似JSON的结构，你向模型精确描述了工具的功能和用法。

两步式调用

第一次调用

```
response = client.chat.completions.create(  
    messages=messages,  
    tools=tools  
)
```

发送原始问题和工具定义，获取模型的执行意图 (tool_calls)。

第二次调用

```
second_response = client.chat.completions.create(  
    messages=messages_with_function_response  
)
```

将函数执行结果追加到对话历史中，再次调用模型，生成最终的人类可读答案。

Function Calling: 通向无限能力的网关

任何可以通过API访问的功能，都可以成为大模型的工具。



架构模式：检索增强生成

Retrieval Augmented Generation


RAG

RAG是一种先进的LLM应用架构。它让模型在生成回答之前，首先从外部的、权威的知识源中**检索 (Retrieve)** 相关信息，然后将这些信息作为上下文**增强 (Augment)** 原始提示，最终**生成 (Generate)** 一个更准确、更具时效性的回答。

这就像给模型一本可以随时查阅的、实时更新的参考书，而不是只依赖它脑海里过时的记忆。

思维跃迁：从提示工程师到AI应用架构师

提示工程师



思维模式：战术驱动 (Tactical)

关注点：寻找“魔法咒语”，优化单个提示词的措辞和结构。

AI应用架构师



思维模式：系统驱动 (Systemic)

关注点：设计一个信息和工具能够顺畅流动的系统，赋能LLM完成复杂任务。

从关注‘如何问问题’，转变为关注‘如何为模型提供解决问题的资源’。

开始构建你的第一个智能系统



AI的真正力量，不在于与它对话，而在于构建能够让它观察、思考和行动的系统。你的架构师之旅，现在开始。