



解锁AI大模型的全部潜力

深入理解检索增强生成（RAG）的工作机制



大模型知道一切，除了那些对你最重要的事



通用大语言模型（如GPT-4o，Deepseek）拥有海量的世界知识，但它们无法访问你公司的内部信息、最新的研究报告或私有数据库。

直接将内部信息“喂”给大模型为何行不通？

将海量内部信息直接输入模型的上下文窗口会带来三大挑战：



1. 模型无法读取所有内容 (Limited Context Window)

大多数模型的上下文窗口有限，无法一次性处理完整的知识库。



2. 模型推理成本高 (High Inference Cost)

处理更长的输入文本会显著增加计算成本和API调用费用。



3. 模型推理慢 (Slow Inference Speed)

输入越长，生成回应的速度就越慢，影响用户体验。

解决方案：检索增强生成（RAG）

RAG是一种让大模型能够访问和利用外部知识库的技术，它并非重新训练模型，而是在生成答案前，先为其提供相关的“开卷资料”。




检索 (Retrieval)

从您的知识库中精确查找
与问题相关的信息。



增强 (Augmented)

将检索到的信息“增强”
到用户的问题中，为模
型提供上下文。




生成 (Generation)

大模型基于增强后的信
息，生成一个准确、有
据可依的答案。

RAG 的工作流程：两阶段方法

准备阶段（提问前 / 离线）



将您的私有数据处理并构建成一个可供快速检索的知识库。

回答阶段（提问后 / 在线）



当用户提问时，实时地检索相关信息并生成答案。

准备阶段 · 步骤 1：分片

RAG的第一步是将庞大的文档分解成更小、更易于管理的信息“片段”(Chunks)。这确保了检索的精确性，因为模型可以专注于最相关的文本片段，而不是整个文档。

Common Chunking Methods:

- 按字数分 (By character count)
- 按段落分 (By paragraph)
- 按章节分 (By chapter/section)
- 按页码分 (By page number)




准备阶段 · 步骤 2：索引

“索引”是为知识库建立一个高效的“目录”。这个过程通过一个名为Embedding的模型，将每个文本片段的语义含义转换成一个数学表示——向量。


The Two Core Actions of Indexing:

1. 文本向量化 (Text to Vector)：使用Embedding模型将每个文本片段转换为一个向量。
2. 存入数据库 (Store in Database)：将原始文本片段和其对应的向量一同存入专门的向量数据库中。




核心概念：什么是Embedding?

Embedding是将文本的复杂语义压缩成数字向量的过程。在这个向量空间中，意思相近的文本在空间上的距离也更近。



回答阶段 · 步骤 1: 召回


“召回”是在用户提问时，从向量数据库中快速搜索并找出与问题最相关的N个文本片段的过程。



技术细节：向量相似度如何计算？


向量数据库通过计算向量之间的“距离”或“角度”来判断其内容的相似性。距离越近或夹角越小，代表语义越相似。

Noto Sans SC Regular



余弦相似度 (Cosine Similarity)

计算两个向量之间夹角的余弦值。夹角越小，相似度越高。是目前最常用的方法。



欧氏距离 (Euclidean Distance)

计算两个向量在空间中的直线距离。距离越近，相似度越高。



点积 (Dot Product)

计算两个向量的对应元素乘积之和。同时反映了向量的大小和方向关系。


回答阶段 · 步骤 2：重排

“重排”是对“召回”阶段返回的初步结果进行更精细的二次排序。它使用更复杂、更精确（但通常也更慢）的模型来确保最相关的片段排在最前面。

	召回 (Retrieval)	重排 (Reranking)
方法 (Method)	向量相似度 (Vector Similarity)	跨编码器模型 (Cross-encoder)
特点 (Features)	成本低、耗时短、准确率相对低	成本高、耗时长、准确率高
适合场景 (Use Case)	初步筛选，从海量数据中快速捞出候选集	精挑细选，对小范围候选集进行精准排序

回答阶段 · 步骤 3：生成

在最后一步，系统会将原始的用户问题和经过重排后的、最相关的文本片段一起打包，形成一个丰富的提示(Prompt)，并发送给大语言模型。




大模型基于提供的参考资料，生成一个内容丰富、事实准确的答案，并返回给用户。

RAG 全链路回顾

提问前 / Offline (Preparation)

提问后 / Online (Answering)



RAG：为通用大模型装上企业专属的“外挂记忆”

RAG不仅仅是一项技术，它是一座桥梁，连接了通用AI的强大推理能力与企业独有的、私有的知识资产。通过RAG，您可以构建一个既博学又专业的AI系统，真正解决特定领域的核心问题。

它让AI从一个“无所不知的通才”转变为一个“了解您业务的专家”。

