



LlamaIndex: 构建基于行业数据的LLM应用

释放私有数据的力量，打造更智能、更精准的AI解决方案



议程：我们的探索之旅



挑战与机遇：通用大模型的知识局限性



核心理念：RAG：什么是检索增强生成（Retrieval-Augmented Generation）？



核心框架：LlamaIndex：解构 LlamaIndex 的工作流程



第一阶段：构建知识库（索引）：从原始数据到可检索的知识



第二阶段：检索与生成（查询）：从用户问题到精准回答




总结与展望：回顾关键步骤，开启您的实践

通用大模型的困境：强大但“无知”

大型语言模型（LLM）拥有强大的通用知识，但在面对特定行业或企业的私有数据时，它们面临着三大挑战：

- **知识鸿沟（Knowledge Gap）**：LLM的训练数据是公开的，截止于特定日期，无法访问您的内部文档、数据库或实时信息。
- **幻觉问题（Hallucination）**：当被问及超出其知识范围的问题时，LLM 可能会“编造”看似合理但错误的答案。
- **缺乏动态更新（Lack of Dynamism）**：业务数据在不断变化，而重新训练整个模型成本高昂且不切实际。

核心问题：如何让LLM安全、准确地利用我们独特的行业数据？



破局之道：检索增强生成（RAG）

RAG是一种将信息检索与语言模型（LLM）的文本生成能力相结合的架构。它不是重新训练模型，而是为其外挂一个“知识库”。

工作原理：




核心价值：

- 扩展知识边界：让 LLM 能够“看到”私有数据。
- 减少幻觉：答案基于检索到的事实，而非凭空猜测。
- 支持动态更新：只需更新知识库，无需重训模型。

您的专属RAG框架：LlamaIndex


LlamaIndex 是一个开源的数据框架，旨在简化连接自定义数据源与大型语言模型（LLM）的过程。您可以把它想象成一个“数据-模型”之间的超级连接器和工具箱。



LlamaIndex = 轻松构建、部署和评估RAG应用的端到端解决方案


LlamaIndex 的两大核心阶段

LlamaIndex将构建RAG应用的复杂过程简化为两个清晰的阶段。



第一阶段：构建知识库（索引）

将非结构化数据转化为LLM的“外部记忆”



索引流程 (1/3): 数据连接器 (Data Connectors)

功能


自动从各种来源摄取数据，并将其统一转换为 LlamaIndex 内部的 `Document` 对象。

支持的常见数据源

- 文件: PDF, Word, Markdown, TXT
- 数据库: SQL, MongoDB
- 在线平台: Notion, Confluence, Google Docs
- API / Web: 网页抓取, REST 接口

核心价值

无需为每种数据源编写繁琐的解析代码，实现“开箱即用”的数据连接。



索引流程（2/3）：文档（Documents）与节点（Nodes）

摄取的数据被构造成两个核心对象：

Document

定义：原始数据源的容器，例如一个完整的PDF文件或一篇Notion文章。它包含文本内容和元数据（metadata）。

`Node`

定义：LlamaIndex中数据处理的原子单位。一个`Document`会被分割成多个`Node`（也称为“块” - chunk）。


作用：每个`Node`包含一小段文本和与源`Document`的关联信息。精细的`Node`划分是实现精准检索的关键。

从宏观到微观：Document → Nodes



索引流程（3/3）：索引（Indexes）

功能：将 `Nodes` 组织起来，构建成高效的数据结构，以便快速检索。




常用索引类型

索引类型	核心思想	适用场景
VectorStoreIndex ☆	将文本转换为向量，通过向量相似性查找相关内容。	最常用。 适用于语义搜索、问答。
SummaryIndex	对每个Node的内容进行总结，构建分层摘要。	快速对大量文档进行摘要。
KeywordTableIndex	提取每个Node的关键词，构建关键词-Node映射。	适用于关键词明确的查询。
KnowledgeGraphIndex	从文本中提取实体和关系，构建知识图谱。	探索数据间的复杂关系。

第二阶段：检索与生成（查询）

从用户的自然语言问题到LLM生成的智慧答案



查询流程（1/2）：检索器（Retrievers）



功能

根据用户查询，从已构建的 `Index` 中高效地找出最相关的 `Nodes`。

核心任务


理解查询意图，并匹配到最可能包含答案的知识片段。

支持多种检索方式

-  **向量/语义检索（Semantic Search）**：基于含义的相似度进行查找。
-  **关键词检索（Keyword Search）**：基于精确的关键词匹配。
-  **混合检索（Hybrid Search）**：结合语义和关键词的优势，提升检索的全面性和准确性。
-  **结构化检索（Structured Search）**：在元数据上进行检索（如时间范围、作者）。

示例：用户问“去年营收是多少？” → 检索器返回包含“财务报告”、“2023年”相关内容的 Node。





查询流程（2/2）：响应合成器 (Response Synthesizers)

功能


将检索器找到的 `Nodes`（上下文）和用户的原始查询整合起来，交由LLM处理，并生成最终的、连贯的自然语言答案。

这是RAG流程中“生成” (Generate)的关键环节。

支持多种合成策略

- **Refine**：迭代地处理每个检索到的文本块，逐步优化和完善答案。
- **Compact**：将多个文本块的内容“压缩”并整合到LLM的提示词中，一次性生成答案。
- **Tree Summarize**：以树状结构递归地总结文本块，适用于需要从大量信息中提炼核心观点的情况。
- **Simple**：直接将所有信息拼接后生成。

完整流程：从数据到决策



总结：用 LlamaIndex 激活您的数据智能

我们探索了

问题（Why）

通用LLM无法利用您的私有行业数据。



方案（What）

RAG架构通过“检索-增强-生成”模式解决了这个问题。



工具（How）

LlamaIndex将RAG的实现简化为两个核心阶段：

1. **索引**：将您的数据构建成一个可检索的知识库。
2. **查询**：基于该知识库，智能地回答用户问题。



您的下一步

-  **探索**：访问 LlamaIndex 官方文档，查看丰富的用例。
-  **实践**：选择一个简单的数据源（如公司内部的PDF文档），尝试构建您的第一个查询引擎。
-  **思考**：如何将这项技术应用于您的核心业务场景，以提升效率、创造价值？