



# 大模型微调原理

从通用到专属，释放AI的真正潜能

# 本次分享大纲



## 1. 为何需要微调？

探索通用大模型的局限与潜能



## 2. 核心原理揭秘

详解模型微调的五步关键流程



## 3. 高效方法论

全量微调 vs. 参数高效微调 (PEFT)



## 4. 实战快速上手

Llama-Factory一站式平台演练



## 5. 总结与展望

回顾核心要点，探讨未来方向

# 通用大模型：才华横溢，但并非“全能专家”

大模型虽在通用语料库上预训练，学会了广泛的语言基本规律，但对特定领域（如医疗、法律、金融）或特定任务（如情感分析、有倾向性的内容生成）缺乏针对性。



## 1. 知识注入 (Knowledge Injection)

让模型学习特定领域的专业术语和事实知识，成为行业专家。



## 2. 迁移学习 (Transfer Learning)

在自有数据量不足时，借力大模型的通用能力，通过少量标注数据快速训练新任务，节约算力、收敛更快。



## 3. 任务对齐 (Task Alignment)

训练模型按特定格式（如分类、摘要、JSON）或逻辑输出，使其更符合目标任务的范式。



## 4. 领域适应 (Domain Adaptation)

调整模型的语言风格和表达习惯，使其更贴合特定场景（如企业客服口吻、特定社群用语）。



# 核心原理揭秘

五步打造专属AI模型

# 模型微调的“五步法”蓝图



# 第一步：选择基石 - 准备预训练模型



## 什么是基座模型？

一个已经过海量通用数据训练好的大模型，如：ALBERT, LLaMA, ChatGLM, Qwen。

## 为何重要？

- 这些模型已掌握了语言的基本规律、常识和表达能力，为微调提供了坚实的“地基”。
- 好比一个已经读完大学的通才，我们只需稍加点拨就能成为特定领域的专家。

## Where to Find Them

常见选择包括 Hugging Face 上的开源模型、云厂商提供的基础大模型等。


 LLaMA

 ChatGLM

 Qwen

 Hugging Face

## 第二步：准备养料 - 准备目标任务数据



### 数据质量 > 数据数量

收集与目标任务高度相关、标注清晰的高质量数据集是成功的关键。

### Common Data Types & Formats

- 情感分析: [文本, 正面/负面]
- 文本分类: [文本, 类别标签]
- 对话任务: 指令-输出对




### Practical Example (from Llama-Factory)

```
[
  {
    "conversations": [
      {
        "from": "human",
        "value": "你好, 请介绍一下你自己。"
      },
      {
        "from": "gpt",
        "value": "我是腾讯的AI助手..."
      }
    ]
  }
]
```

## 第三步：格式对齐 - 让模型“听懂”你的数据

目标：将原始文本数据转换为模型能够处理的数字格式（Token IDs）。



**CRITICAL RULE:** 数据预处理时使用的分词器（Tokenizer）必须与预训练模型使用的分词器完全一致，否则模型将无法正确理解输入。


## 第四步：配置与训练 - 效果与成本的艺术

### Key Hyperparameters

- 学习率 (Learning Rate)：控制参数更新的步长 (e.g.,  $2e-5 \sim 5e-5$ )
- 批大小 (Batch Size)：每次训练处理的数据量
- 训练轮次 (Epochs)：完整数据集的训练次数 (e.g., 2 ~ 10轮)



全量微调  
(Full Fine-tuning)




参数高效微调  
(PEFT)

| 特性   | 全量微调 (Full Fine-tuning) | 参数高效微调 (PEFT)，如 LoRA |
|------|-------------------------|----------------------|
| 更新对象 | 全部模型参数                  | 少量额外参数 (适配器层)        |
| 计算资源 | 极高 (VRAM密集型)            | 较低 (消费级显卡也可行)        |
| 训练速度 | 慢                       | 快                    |
| 适用场景 | 任务差异巨大，追求极致性能           | 资源有限，快速迭代，领域适配       |

PEFT (尤其是LoRA) 作为一种“部分微调”，极大地降低了微调门槛，是当前主流选择。

## 第五步：验证与部署 - 创造并迭代价值





# 实战演练：Llama-Factory

一站式平台，让微调触手可及

# 三步完成微调准备



# 一键启动训练，实时监控进程

## Configuration

 **Llama-Factory**






学习率 (Learning Rate)

训练轮次 (Epochs)

 **开始 (Start)**

## Monitoring



# 微调的价值：从“标准答案”到“专属身份”



你好，你是谁？

微调前 微调前 - 基础模型

我是一个由阿里巴巴集团开发的  
智能助手...



微调后 微调后 - 专属模型

我是**腾讯**的AI助手，名为“我”。  
我由**腾讯**旗下的**腾讯计算机有限**  
**公司**开发...



通过微调，我们成功地为模型注入了全新的身份认知。

# 总结：从原理到实践的核心要点



## 微调是释放潜能的关键 (Fine-tuning Unlocks Potential)

它弥合了通用模型与特定需求之间的差距，实现AI的真正价值。



## “五步法”是成功的路线图 (The '5-Step Method' is the Roadmap)

遵循结构化的流程（模型->数据->预处理->训练->评估）是高效、可复现微调的保证。



## 效率与效果可以兼得 (Efficiency Meets Performance)

以LoRA为代表的参数高效微调 (PEFT) 技术，在保证效果的同时，极大地降低了微调的资源门槛。



## 工具让实践更简单 (Tools Simplify Practice)

Llama-Factory等一站式平台，将复杂的流程简化为直观的图形化操作，让先进技术触手可及。