



MoA是什么？它与MoE的区别是什么？

解构下一代AI协作架构：从专家混合到智能体混合

本次议程：从概念到实践，全面解析MoA



1. 基石：专家混合（MoE）架构解析 – 我们从哪里开始？



2. 演进：智能体混合（MoA）核心思想 – 新范式是什么？



3. 核心对比：MoE vs. MoA 的关键区别 – 两者究竟有何不同？




4. 实证：MoA 的工作原理与性能表现 – 它真的有效吗？



5. 总结：核心要点回顾


一、专家混合 (MoE) : 让一个大脑拥有多个“专 科部门”

MoE是一种稀疏模型架构，通过“条件计算”在单个大模型内部激活特定专家，旨在性能和计算效率之间取得平衡。




MoE架构：由“路由器”智能调度，仅激活部分专家

- **核心单元：**专家（Expert） - 本质是同质的子模型（或称为前馈网络）。
- **调度机制：**路由器（Router/Gating Network） - 一个小型网络，根据输入内容，计算并选择性地激活一个或多个最相关的专家来处理任务。
- **主要优势：**
 - **计算效率高：**只用部分专家进行计算，节省了大量算力。
 - **模型容量大：**可以在不显著增加计算成本的情况下，将模型参数扩展到超千亿级别。




二、智能体混合（MoA）：组建一支“各有所长的AI梦之队”

MoA是一种系统级的设计范式，它编排多个独立的、能力各异的AI智能体（Agent）协同工作，工作，以解决单一模型难以胜任的复杂任务。



MoA架构：通过“多轮协作”凝聚集体智慧



- **核心单元：智能体（Agent）** – 通常是独立的、功能完整的、异构的LLM。每个Agent都可以是具备特定能力的模型或工具。
- **协作机制：**多个智能体通过迭代的方式，逐步完善和增强解决方案。前一个智能体的输出可以作为后一个智能体的输入。
- **主要优势：**
 - **解决复杂任务：**能处理单一模型难以胜任的多步骤、复杂推理任务。
 - **可解释与模块化：**每个智能体的贡献清晰，系统易于扩展和维护。



三、核心对比：内部优化 vs. 外部协作

维度 (Dimension)	MoE (专家混合)	MoA (智能体混合)
核心思想	稀疏激活专家网络以提高模型容量与效率	多个智能体协同工作以完成复杂任务
架构单元	专家 (Expert)：同质的子模型	智能体 (Agent)：可异构，功能不同
激活方式	由路由器选择少数专家	通过任务调度或协作机制调用多个Agent
应用场景	LLM中提升推理效率，参数高效利用	多任务处理、复杂推理、多工具联动场景
架构层级	通常是LLM内部的一种结构设计	通常是系统级的框架，可以集成多个LLM、工具等

一言以蔽之：MoE优化模型“内部”，MoA编排模型“之间”




“MoE好比一个大脑内的多个人格，MoA则好比一个房间里的多个大脑。”

四、实证：MoA的迭代式工作流程如何提升性能？

MoA的性能提升源于其多层、迭代的推理过程。每一层的智能体都会参考前一层的结果，进行修正和增强，从而逐步提升答案的质量。


- 1. **初始生成**：第一层的多个LLM针对初始输入，各自生成独立的初步想法。
- 2. **逐层精炼**：这些初步想法被整合后，作为输入传递给下一层的LLM。
- 3. **迭代优化**：这个过程在多个层级中重复进行，每一层都对解决方案进行再思考和优化。
- 4. **最终聚合**：最后一层的输出被聚合成最终的、更高质量的答案。



实验数据：MoA架构显著优于单一模型

在多项测试中，采用MoA协作机制（接收其他模型的回应）的模型，其表现一致优于独立运行的单一模型。

单一模型 vs. MoA 性能对比



性能基准： MoA表现媲美甚至超越顶尖模型

通过将GPT-4o作为聚合器， MoA架构在AlpacaEval 2.0基准测试中取得了78.7%的胜率，超越了包括GPT-4 Turbo在内的多个顶尖模型。

模型 (Model)	AlpacaEval 2.0 (LC Win %)
MoA w/ GPT-4o	78.7%
MoA (base)	65.1%
GPT-4 Turbo (04/09)	57.5%
WizardLM-2 8x22B	51.3%

★ 通过顶尖模型的协作， MoA展示了SOTA级别的性能。

总结：核心要点回顾

1



1. MoE 是“模型内”的优化：通过激活部分“专家”子网络，实现计算效率和模型规模的平衡。它是**单一模型的增强技术**。

2



2. MoA 是“模型间”的协作：组建独立的AI“智能体”团队，通过多轮迭代协同解决复杂问题。它是**多模型的编排框架**。

3



3. 性能源于协作：MoA的集体推理机制已被证明能有效提升任务完成质量，其表现超越了单个模型的局限，展现了SOTA级别的潜力。



Thank You

Q&A