



模型微调数据集创建工具：Easy dataset

轻松将任何文档，转化为高质量微调数据

本次分享大纲

- 1 痛点剖析：为何高质量微调数据集如此难得？
- 2 行业现状：公开数据集平台的机遇与局限
- 3 破局之道：Easy dataset 核心架构与价值
- 4 实战演练：从零到一，四步构建专属数据集
- 5 核心总结：开启高效数据创建之旅



微调的成败，七分靠数据


高质量、领域专属的数据集是模型微调成功的关键，但其创建过程充满挑战。



耗时费力：手动撰写和标注QA对，流程冗长，效率低下。



专家依赖：高质量数据依赖领域专家，成本高昂且难以规模化。



格式繁琐：处理PDF、Markdown等非结构化文档，格式转换与清洗工作复杂。



工具匮乏：缺少能够将整个流程自动化的开源、本地化工具。

“构建领域微调数据集需要解决的核心问题：完全不懂业务的人工去标，质量堪忧；直接标文档给AI，但是AI对于大文件生成的QA对效果比较差...”

现有公开数据集平台：巨人的肩膀与未及之地


HuggingFace、Kaggle、OpenDataLab、ModelScope等平台是获取公开数据集的宝贵资源，但它们共同的空白在于——私有知识的自定义数据集创建。

平台	语言领域	数据量级	语言侧重	特色功能
HuggingFace	NLP/多模态	大	英文	即装即用、社区活跃
Kaggle	通用型	超大	多语言	竞赛生态、数据科学
OpenDataLab	中文场景	中	中文	本土化支持、多模态
ModelScope	中文AI应用	大	中文	模型-数据协同

结论：公开数据集虽好，但无法满足企业利用内部知识库进行特定领域微调的需求。

为专业微调而生：Easy dataset 核心架构

一个开源、支持本地部署的强大工具，专注于将您的非结构化文档，自动化生成高质量微调数据集。



实战演练 1/4：环境准备 - 一键本地化部署

Easy dataset 支持 Docker 快速部署，保障数据安全与私密性。

1. 克隆仓库

```
git clone https://github.com/ConardLi/easy-dataset.git  
cd easy-dataset
```

2. 构建 Docker 镜像

```
docker build -t easy-dataset .
```

3. 运行容器（注意替换本地路径）

```
docker run -d -p 1717:1717 -v {YOUR_LOCAL_DB_PATH}:/app/local-db --name  
easy-dataset easy-dataset
```

引导：浏览器访问 `http://localhost:1717` 即可开始。

实战演练 2/4：知识处理 — 从源文档到结构化文本

步骤一：连接你的大模型（LLM）

模型配置

+ 添加模型



Ollama (本地部署)



OpenAI (gpt-4o)



DeepSeek



阿里通义千问 (qwen-plus)



智谱AI (glm-4-flash)

重点：用户只需提供API Key和端点地址，即可轻松集成。

步骤二：上传与解析



`DjangoBook2.0中文版.pdf`



Markdown



Django 2.0 中文翻译

The Django Book

最近更新 - 贡献者

- 第一章：介绍Django

- 第二章：入门

JetBrains Mono

Source Han Sans SC Normal

实战演练 2/4：知识处理 - 智能分析与领域洞察

核心功能：文档处理完成后，工具会自动进行**智能分块**（Chunking）和**领域分析**（Domain Analysis）。

智能分割

已选择 0 个文本块，共 272 个文本块

markdown-part-1

markdown-part-2

...

领域分析

魔法的魔法时间，并为自动生成的领域树

1 Django基础

1.1 框架介绍

1.2 安装配置

2 数据库操作

...

9 安全防护

9.1 SQL注入防护

9.2 XSS防护

核心价值：自动化的结构理解，为后续按章节、按主题生成和管理问答对奠定了坚实基础。

实战演练 3/4：批量生成 - 将文本转化为高质量问答对


1. 批量选择文本块



2. 任务配置



3. 生成结果预览



实战演练 4/4：审核与优化 - 确保数据质量的最后一公里

****核心理念*：** 自动化生成 + 人工审核 = 高质量数据集。

领域树

1 Django基础

1.1 框架介绍

1.2 安装配置

2 数据库操作

1.1 框架介绍

1.2 安装配置

3 数据库件操作

2.1 安装配置

问题管理

+ 问题问管理

问题：如何安装 Django?
答案：使用 pip install django 命令。
AI 优化

问题：Django 的优势是什么?
答案：Django 是一个高级 Python Web 框架。
AI 优化

问题：Django 的优势是什么?
答案：Django 是一个高级 Python Web 框架。
AI 优化

AI 优化建议

建议的优化答案：
使用 pip install django 命令是最常见和推荐的方法。此外，建议在虚拟环境中进行安装，以避免依赖冲突。确保您的 Python 环境已设置。

采纳

取消

NotebookLM

实战演练 4/4：一键导出 - 适配多种训练框架

导出数据集

导出到本地

文件格式

☐ JSON

☒ JSONL

☐ CSV

数据级风格

☒ Alpaca

☐ ShareGPT

☐ 自定义格式

格式示例

```
{  
  "instruction": "...",  
  "input": "...",  
  "output": "..."  
}
```

上传到云端

上传至 Hugging Face

数据集名称

上传

核心价值：灵活的导出选项，确保生成的数据可以无缝对接到用户的模型训练流程中。

NotebookLM

Easy dataset 的核心价值



自动化

将繁琐的文档解析、文本分块、QA生成流程完全自动化，极大提升效率。



专业化

专为特定领域知识设计，深度挖掘私有文档价值，构建专家级微调数据集。



可控性

从本地化部署的数据安全，到人机协同的数据精炼，提供全流程的自主可控。