


为什么说
AI大模型微调中
最不需要
关注的就是GPU




我们的探索路径



普遍的误区：“微调就是一场GPU的军备竞赛”




核心隐喻：微调的成功，如同驾驭一座冰山




你所看到的，只是冰山一角。真正的挑战，潜藏于水下。


水下基石 ①：数据质量是模型能力的上限



垃圾进，垃圾出
(GIGO)



领域相关性
(Domain Relevance)




高质量标注
(High-Quality Labeling)



数据多样性与一致性
(Diversity & Consistency)

“80%的工作在这里”：高质量指令集的诞生过程



这不是一个技术问题，这是一个需要极大耐心和领域知识的工程问题。

水下基石②：错误的航向，再快的船也无法到达目的地



为什么是微调？

对比 RAG, Prompt Engineering.
你真的需要微调吗？



成功的标准是什么？

定义可量化的评估指标（业务指标，而非单纯的技术指标）。



选哪个基础模型？


不同模型的“性格”和能力天花板不同。

水下基石③：选择比努力更重要——技术选型决定资源需求



Full Fine-Tuning
(全量微调)

PEFT (参数高效微调)
e.g., LoRA, QLoRA



优点：效果潜力最大


缺点：成本极高，需要大量GPU

优点：资源友好，单张消费级GPU即可运行

缺点：效果可能略有损失

99%的场景，PEFT是更明智的选择。

水下基石④：没有可靠的评估，微调就是在黑暗中赌博



快速迭代的能力，远比单次训练的算力更重要。


微调成功的全景图




你的注意力，应该放在哪里？

那么，GPU到底扮演什么角色？

数据 & 策略



GPU



GPU是**执行者**，不是**思考者**。

它不解决“做什么”和“怎么做对”的问题，它只负责把你的计划**加速**执行。

糟糕的计划 + 强大的GPU = 更快、更昂贵的失败

算力，一个基本被“解决”了的问题



获取算力，是预算问题，不是准入问题。

- 通过云服务和平台，你可以按小时租用世界上最顶级的GPU。

但你租不来：



- 对你业务场景的深刻理解




- 高质量的、领域专属的数据集



- 团队的迭代和试错经验

新的微调世界观：成功需求金字塔



先有坚实的地基，再考虑塔尖的辉煌。

你的新行动指南



痴迷于数据 (Obsess over data)

像对待代码一样，对数据进行版本控制、审查和测试。



先定义成功 (Define success first)

在写下第一行训练代码前，明确你的评估标准和方法。



聪明地选择工具 (Choose your tools wisely)

优先考虑PEFT，不要盲目追求全量微调。




建立迭代循环 (Build your iteration loop)

目标是快速、低成本地完成一次“训练-评估”循环。



最后，按需获取算力 (Finally, acquire compute as needed)

当且仅当你已具备前四项时，再为算力付费。



从关注算力，到关注问题本身

(From focusing on compute, to focusing on the problem itself.)