

LLM的局限性与RAG技术引入

为强大的AI大脑连接一个实时更新的外部知识库



本次分享大纲

01. LLM的原理及优势

我们从何处开始？



02. LLM的局限性

我们面临的挑战是什么？



03. LLM的增强策略

如何突破瓶颈？



04. RAG的优势

为什么RAG是关键？




05. 总结与收尾

关键点与未来展望



01. LLM的原理及优势

LLM：我们身边的代码副驾驶与创意伙伴



大语言模型（LLM）已经成为我们开发工具箱中的重要一员。无论是请求AI编写一个函数，还是让它帮助我们理解复杂的概念，LLM都展现了惊人的能力。

LLM的核心工作原理：魔法背后的机制



1. Transformer架构

利用自注意力 (Self-Attention) 机制高效处理文本序列，动态关注上下文中的关键信息。

***关键点*：**能在长篇文本中快速定位重要词汇的关联。


2. 预训练与微调

在海量数据上学习通用语言规律（预训练），再针对特定任务进行优化（微调），以适应不同应用场景。

3. 概率预测生成

根据输入的上下文，预测最可能的后续词句，从而生成流畅、连贯的文本。

我们为何如此依赖LLM？四大核心优势



强大的语言生成能力

无论是撰写文章、生成代码，还是进行对话，都能输出高质量文本。



上下文理解能力

能够捕捉长距离的语义依赖，准确回答复杂问题。（例如：在法律文件中理解条款关联）



泛化性

通过预训练积累通用知识，无需为每个任务重新训练即可应对翻译、摘要、问答等多种任务。



提升效率

快速生成大规模文本，极大降低人工内容创作门槛，成为开发者的理想AI助手。

强大背后的“裂痕”：我们必须正视的挑战

- LLM的核心是基于训练数据的**统计规律**进行预测，这导致它缺乏对真实世界的深入理解。
- 它无法理解复杂的**因果关系**，只是根据数据模式生成内容。



- 这些根本性的问题，导致了模型在**高可靠性场景**中的应用受限。

局限性一：一本正经地胡说八道——“幻觉”风险



2025年亚洲杯女足冠军是哪个队？



中国队在决赛中以3-1击败了日本队，夺得冠军。

幻觉!

什么是幻觉 (Hallucination)

生成看似合理但与事实不符或矛盾的内容。例如，在描述历史事件时，编造不存在的细节。


原因分析

根源在于模型过度依赖统计模式，而非事实验证。它根据数据中的模式生成内容，但缺乏对真实性的判断。

错误风险

在医疗、法律等关键领域，幻觉可能导致致命的错误建议，引发严重后果。


局限性二与三：被时间困住的“静态大脑”



1. 训练数据的时间局限性（知识截止）

LLM的知识通常截止于某个固定时间点（如2023年），无法获取最新信息。

***开发者痛点*：**当需要回答关于当前股价趋势或最新技术发布的问题时，模型会给出过时或错误的答案。



2. 小众/私有知识的覆盖不足（数据盲区）

训练数据以公开文本为主，无法学习企业内部的专有知识、流程或API文档。

***开发者痛点*：**无法构建一个能准确解答公司内部特定问题的智能助手。

突破局限：为LLM装备“超级外挂”

核心目标：弥补知识缺口、减少幻觉、提升任务适应性。



模型微调 (Fine-tuning)

通过在特定领域的高质量数据上进行二次训练，优化模型输出。



RAG (检索增强生成)

通过检索外部知识库来补充知识。



工具调用 (Tool Use)

调用外部API或工具（如计算器、搜索引擎）来处理模型不擅长的任务。

核心方案：RAG（检索增强生成）

RAG原理

通过结合外部知识库，在生成文本前检索相关信息，为模型提供最新的、准确的上下文。


动态更新

知识库可以随时更新，彻底打破了LLM静态知识库的局限。例如，医疗知识库更新后，RAG可以立即基于最新的医疗信息生成建议。




RAG技术揭秘：从文本到向量的检索之旅

Phase 1: 知识索引 (Indexing)



Phase 2: 实时检索 (Retrieval)



Phase 3: 增强生成 (Generation)



04. RAG的优势

为什么RAG是高效、低成本的增强方案？



成本低

无需额外算力训练或微调模型，只需维护知识库即可实现知识更新，极大降低了本地化部署和维护成本。



知识更新

知识库可随时动态更新，彻底打破LLM的知识截止局限。新闻机构、医疗系统等场景的理想选择。



解决幻觉

答案严格基于提供的上下文文本，极大减少了模型凭空捏造信息的风险，提高了答案的可信度和可追溯性。



领域定制

可以轻松注入特定领域的专业知识（如内部代码库、财务报告），让通用模型变为领域专家。

05. 总结与收尾

关键总结：从理解局限到拥抱增强

LLM的挑战



RAG解决方案



LLM的核心回顾

我们认识到LLM基于Transformer架构，拥有强大的语言生成和上下文理解能力，但其本质是统计学习，存在知识截止、幻觉等固有问题。

RAG的关键作用

RAG通过检索外部知识库，解决了LLM的知识局限性问题。它能动态更新知识、减少幻觉、提升专业性，并且成本低廉，是增强LLM最有效的方案之一。

未来展望：RAG驱动下一代智能应用

随着技术的不断发展，RAG将在更多领域发挥重要作用，成为构建可靠、实用AI应用的核心基石。

