




# 如何评估RAG：从核心指标到自动化框架

---


量化成效，驱动迭代，打造高质量的AI应用



# 您的RAG系统，是“感觉良好”还是“数据证明”？



主观感觉



数据驱动

主观判断无法指导优化。我们需要一个系统的评估框架，将**RAG**的“黑盒”变成“白盒”，实现**量化成效**，**快速迭代**。




# 本次分享大纲


- 1 评估蓝图：解构RAG，锁定关键评估节点
- 2 检索质量评估：我们找对、找全知识了吗？
- 3 生成质量评估：答案是否忠实、有用？
- 4 评估实战：从人工评估到自动化框架
- 5 深度总结：构建端到端的持续评估体系

# RAG系统评估蓝图

## 检索阶段




## 生成阶段



我们将逐一解构这两个核心阶段的评估方法。



# 检索质量评估：好答案始于好材料



检索阶段 (Retrieval Phase)

生成阶段 (Generation Phase)



- **找得准 (Precision) :** 召回的结果都是相关的?




- **找得全 (Recall) :** 召回所有相关的知识?

这两个问题引出了信息检索领域最经典的两个评估指标：**精确率与召回率**。



# 核心指标：精确率（Precision）与 召回率（Recall）



$$\text{精确率 (Precision)} = C / B$$

检索出的结果中，相关文档的比例。（衡量**查准率**，宁缺毋滥）



$$\text{召回率 (Recall)} = C / A$$

相关的结果中，被成功检索出的比例。（衡量**查全率**，宁滥勿缺）


精确率和召回率是衡量检索性能的基石，两者往往需要权衡。



# 生成质量评估：最终交付给用户的价值



- **忠实原文 (Faithfulness)：** 不捏造、不曲解上下文信息？



- **解决问题 (Answer Relevance/Accuracy)：** 精准、有效地回应用户意图？

这是决定用户最终体验的关键一环，我们关注两大核心品质：**忠实度与答案相关性**。



# 生成模型的核心品质



## 忠实度 (Faithfulness)

生成的内容是否忠实于提供的上下文或背景信息，是否存在信息捏造（幻觉）。

### 示例

上下文: "报告显示, A公司第一季度利润为100万美元。"

忠实的答案: "A公司Q1利润是100万美元。"

不忠实的答案: "A公司Q1利润高达500万美元。"



## 答案相关性 (Answer Relevance / 准确率)

站在用户视角, 直接评判答案是否符合实际需求, 是否直接、完整地回答了用户的问题。

### 示例


问题: "A公司Q1利润是多少?"

相关的答案: "A公司Q1利润是100万美元。"

不相关的答案: "A公司是一家优秀的公司。" ❌



# 评估方法论：人工与自动化的协同



## 人工评估 (Manual Evaluation)

- 优点：高质量、高置信度、最接近用户体感
- × 缺点：成本高、速度慢、难规模化

## 自动化评估 (Automated Evaluation)

- 优点：速度快、成本低、可规模化、可重复
- × 缺点：指标可能与真实体感有偏差、需要高质量数据集

最佳实践是将两者结合：用自动化进行大规模回归测试，用人工进行抽样深潜和“黄金标准”验证。



# 评估方法详解

## 01 人工评估 (Manual Evaluation)

流程:

1. **准备样本**: 定义测试问题、标准答案、评分标准。
2. **执行测试**: 获取模型作答结果。
3. **人工评判**: 评估者对每个答案的正确性、错误类型进行标注或直接评分。
4. **统计分析**: 计算准确率或平均分。

## 02 模型自动评估 (Model-based Automated Evaluation)

流程:

1. **准备样本**: 定义测试问题、标准答案。
2. **执行测试**: 获取模型作答结果。
3. **模型评分**:
  - **方法1 (相似度)**: 评估标准答案和作答结果的文本相似度。
  - **方法2 (Rerank)**: 将问题+作答结果输入Rerank模型, 得到相关性得分。
4. **统计分析**: 汇总模型评分。



# 前沿方法：利用大模型评估大模型（LLM-as-a-Judge）



## 应用场景

- **评估忠实度:** 判断答案是否完全由上下文支持。
- **评估相关性:** 判断答案与用户问题的匹配程度。
- **评估更多维度:** 简洁性、无害性、语言风格等。



# 善用工具，事半功倍：主流评估框架



LangSmith



Langfuse




RAGs (by Ragas)



TruEra, Arize AI, etc.

## 核心功能



**实验追踪：**记录每次运行的输入、输出和中间过程。



**数据集管理：**创建和维护评估用的“黄金数据集”。



**评估流水线：**自动化运行忠实度、相关性等指标。




**可视化与调试：**深入分析失败案例，快速定位问题。

不要重复造轮子。这些框架是构建专业级RAG评估体系的加速器。



# 建立持续改进的评估飞轮





# 实战案例：A/B测试优化文档分块策略

场景：我们希望验证新的“语义分块”策略是否优于传统的“固定长度分块”。

| 评估维度     | 控制组（固定长度） | 实验组（语义分块） | 结果     |
|----------|-----------|-----------|--------|
| 检索-召回率   | 85%       | 92%       | ▲ +7%  |
| 检索-精确率   | 90%       | 91%       | ▲ +1%  |
| 生成-忠实度   | 95%       | 98%       | ▲ +3%  |
| 端到端用户满意度 | 4.2 / 5   | 4.6 / 5   | ▲ +0.4 |

**结论：**数据清晰地表明，新的分块策略在检索和生成质量上均有显著提升。**决策：**上线新策略。



# 总结：RAG评估的核心思想



## 1. 系统化思维 (Systematic Thinking)

RAG评估是一个系统工程，而非单一指标。必须同时关注链路路上的各个环节。



## 2. 解构主义 (Deconstruction)

将复杂问题分解为**检索质量**（精确率/召回率）和**生成质量**（忠实度/相关性）两个核心，逐个击破。



## 3. 自动化加速 (Automation Acceleration)

善用**自动化评估框架**和**LLM-as-a-Judge**，让数据驱动成为常态，而非偶尔的奢侈品。