


多模态算法ALBEF模型解析

Align before Fuse (先对齐, 再融合)




我们的探索之旅




群雄逐鹿：ALBEF之前的多模态架构

双流模型
(图文并重，平分秋色)




e.g. CLIP

单流模型
(极简主义，主攻融合)



e.g. VisualBERT

ALBEF登场：先对齐，再融合的智慧




核心思想：传统模型在特征未对齐时就进行融合，导致信息损失。

ALBEF创新性地提出：

1. **先对齐：**通过对比学习（ITC），拉近匹配图文的特征距离。
2. **再融合：**将对齐后的特征送入多模态编码器，进行深度融合。

训练支柱 I：图文对比学习（ITC） – 实现“对齐”



目标： 在一个共享的特征空间里，让匹配的图文对（正样本）的特征向量尽可能相似，同时让不匹配的图文对（负样本）的特征向量尽可能疏远。这是实现粗粒度对齐的关键第一步。

训练支柱 II：掩码语言模型 (MLM) - 借助图像“完形填空”




目标：强制模型利用图像信息来理解文本。通过预测被遮盖的词语，模型必须学习图像和深层次的语义联系，从而实现真正的多模态融合。

提供视觉上下文

一只狗正在公园里接住一个 [MASK]。

训练支柱 III: 图文匹配 (ITM) - 精准判断“是不是一对”

ITM 任务: 细粒度判断



目标: 对图文对进行细粒度的匹配判断, 是/否?


策略: 挖掘“困难负样本”




关键策略: 使用ITC分数挑选语义相似但不匹配的“困难负样本”, 迫使模型学习更细微的差别, 而非简单的“找不同”。

三位一体：ALBEF的基础训练目标

$$\text{Loss} = L_{\text{ITC}} + L_{\text{ITM}} + L_{\text{MLM}}$$



ITC




ITM




MLM

现实世界的挑战：网络数据充满“噪声”



问题：大规模训练数据来源于网络，图文对的匹配度低、质量参差不齐。这些“噪声”会误导模型，使其学习到错误的关联。

点睛之笔：用动量蒸馏（MoD）过滤噪声



核心思想：让更稳定的“教师模型”为数据生成更可靠的“软标签”，引导“学生模型”学习，从而有效忽略原始数据中的噪声，实现去噪训练。

终极形态：融合动量蒸馏的损失函数

$$\text{Loss} = \text{L_MoD_ITC} + \text{L_ITM} + \text{L_MoD_MLM}$$

$$\text{L_MoD_ITC} = (1-\alpha) * \text{L_ITC}$$

$$+ \alpha * \text{KL}(q_{\text{ITC}} || p_{\text{ITC}})$$

$\alpha = 0.4$ (控制教师指导的权重)

$$\text{L_MoD_MLM} = (1-\alpha) * \text{L_MLM}$$

$$+ \alpha * \text{KL}(q_{\text{MLM}} || p_{\text{MLM}})$$

KL散度 (Kullback-Leibler Divergence)：衡量学生模型(q)和教师模型(p)预测分布之间的差异。这个惩罚项会迫使学生的预测结果向更可靠的教师看齐。

庖丁解牛：每个组件都不可或缺吗？

#Pre-train Images	Training Tasks	TR (flickr test)	IR (test)	VQA (test-dev)
4M	MLM + ITM	93.96	88.55	71.40
4M	ITC + MLM + ITM	96.55	91.69	73.29
4M	ITC + MLM + ITM_hard	97.01	92.16	73.81
4M	ITC_MoD + MLM + ITM_hard	97.33	92.43	74.06
4M	Full (ITC_MoD + MLM_MoD + ITM_hard)	97.47	92.58	74.42
4M	ALBEF (Full + MoD_Downstream)	97.83	92.65	74.54

加入ITC：性能大幅提升，证明“对齐”是基础！

加入困难负样本：进一步优化匹配精度！

加入MoD：鲁棒性显著增强，效果全面最佳！

横扫千军：ALBEF 与 SOTA 模型的性能对决

Image-Text Retrieval on Flickr30K

Method	# Pre-train Images	TR R@1	IR R@1
UNITER [2]	4M	83.6	68.7
CLIP [6]	400M	88.0	68.7
ALIGN [7]	1.2B	88.6	75.7
ALBEF (4M)	4M	90.5★	76.8★
ALBEF (14M)	14M	94.1★	82.8★


VQA, NLVR², SNLI-VE

Method	VQA (test-dev)	NLVR ² (test-P)	SNLI-VE (test)
VisualBERT	70.80	67.40	-
UNITER	72.70	77.85	78.28
OSCAR	73.16	78.07	79.03
ALBEF (4M)	74.54★	80.24★	80.30★
ALBEF (14M)	75.84	83.14	80.91

ALBEF的核心贡献与启示


1. 核心哲学：验证了“先对齐，再融合”是处理多模态特征的更优范式，为后续研究提供了新思路。

2. 关键创新：证明了通过图文对比学习(ITC)实现预对齐是成功的关键，有效降低了后续融合任务的难度。




3. 现实方案：动量蒸馏(MoD)巧妙地解决了网络噪声数据这一普遍存在的痛点，极大提升了模型在真实场景下的鲁棒性和性能。

从ALBEF的设计中学到的工程智慧




解耦复杂问题

“先对齐，再融合”的本质，是将一个困难的多模态理解问题，分解为两个更简单、更专注的子问题，分而治之。



聪明的“数据清洗”

与其盲目增大含噪声的数据集，不如设计一个聪明的训练策略（如 MoD）来利用好现有数据，质量比数量更重要。



精心设计的“捷径”

精心设计的训练策略，有时比单纯堆砌更多模型参数或数据，能更高效地提升模型能力上限。