

多模态算法BLIP模型深度解析

统一视觉语言理解与生成的革命性框架



BLIP

BLIP: **B**ootstrapping **L**anguage-**I**mage **P**re-training

本次分享大纲



1. 时代背景：视觉语言预训练的两大挑战
2. BLIP登场：统一框架的核心思想
3. 核心架构 (MED)：深入理解三种工作模式
4. 独门秘籍 (CapFilt)：从噪音数据中“炼金”
5. 实验验证：设计选择与性能巅峰
6. 总结展望：BLIP的贡献与未来

挑战一：模型视角的割裂

理解模型
(Understanding Models)



Examples: CLIP, ALIGN




生成模型
(Generation Models)



Example: SimVLM


现有模型通常“术业有专攻”，要么精于理解（如图文检索），要么擅长生成（如图文描述）。训练一个模型同时做好两件事，非常困难。这构成了第一个创新痛点。

挑战二：数据视角的噪音



深度学习模型依赖海量网络图文数据，但这些数据质量参差不齐，充斥着大量与图像内容弱相关甚至无关的“噪音文本”，严重影响模型学习效果。

BLIP登场：一个模型，解决两大难题



BLIP通过两大创新来解决痛点：

- 1、模型视角：提出多模态混合编码器-解码器（MED），一个模型灵活支持理解和生成任务。
- 2、数据视角：提出字幕生成与过滤（CapFilt）策略，解决网络图文数据中的噪音问题。

核心架构：多模态混合编码器-解码器 (MED)




图像编码器 (Image Encoder)



BLIP的核心是一个灵活可变的“瑞士军刀”式架构。它由一个共享的图像编码器和三个可切换功能的文本模块构成，以适应不同的预训练任务。


- 图像编码器 (Image Encoder)：基于ViT，提取图像特征，是所有任务的视觉基础。

MED的三种工作模式




预训练时，这三个任务的目标函数被联合优化，使模型天生具备理解与生成的双重能力。

独门秘籍：Captioning and Filtering (CapFilt)



架构问题解决了，但数据噪音问题依然存在。BLIP的答案是：不要只做数据的消费者，也要做数据的生产者和筛选者。CapFilt利用模型自身的能力来净化和扩充数据集。

核心思想：引导循环，自我进化



这是一个“鸡生蛋，蛋生鸡”的良性循环。模型越强，清洗出的数据质量越高；数据质量越高，训练出的模型就越强。

实验验证一：CapFilt 真的有效吗？

	Bootstrap C	Bootstrap F	Retrieval-FT (COCO)	
			TR@1	IR@1
COCO+VG+CC+SBU (14M imgs)	✗	✗	78.4	60.7
	✓ ^B	✓ ^B	80.6	63.1
			+2.2	+2.4

消融实验结果明确显示：单独使用Captioner (C) 或 Filter (F) 性能都有提升。两者结合使用时，效果达到最佳。这证明了CapFilt策略的巨大成功。

实验验证二：关键设计选择的权衡

Captioner/Filter参数?

Captioner & Filter	Noise ratio
Share parameters	8%
Decoupled ✓	25%

不共享 (Decoupled)

效果更优

文本生成策略?

Generation method	Noise ratio	Retrieval TR@1
None	N.A.	78.4
Beam	19%	79.6
Nucleus ✓	25%	80.6

效果更优

编码器参数共享?

Layers shared	#parameters
All	224M
All except CA	252M
All except SA	252M
None	361M

性能与效率的最佳权衡

作者通过一系列严谨的实验，验证了模型中的多项关键设计，为我们展示了“最优解”是如何通过工程实践被找到的。

最终对决：登顶SOTA的检索性能

Method	Pre-train # Images	COCO (5K test set)						Flickr30k (1K test set)					
		TR			IR			TR		IR			
		R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@10	R@1	R@5	R@10	
UNITER	100M	60.0	55.7	42.0	32.1	42.8	54.3	85.3	85.0	75.5	69.4	72.3	
VILLA	100M	62.5	56.7	46.6	39.0	42.0	56.7	93.7	82.6	77.8	70.7	70.8	
OSCAR	14M	66.3	63.8	49.8	40.5	44.8	52.3	96.2	83.8	83.0	73.8	79.9	
UNIMO	10M	74.5	72.5	49.3	45.2	46.4	60.3	97.5	87.5	82.9	69.5	82.3	
ALIGN	100M	73.9	88.3	50.3	47.4	48.3	66.4	97.0	88.5	85.3	68.1	85.7	
ALBEF	100M	74.9	80.9	51.7	49.9	50.3	60.0	98.0	88.0	86.0	74.4	83.8	
BLIP 14M	14M	74.0	36.6	50.2	61.6	53.0	62.5	97.5	87.5	81.7	74.5	83.8	
BLIP 129M	129M	74.8	38.3	50.6	64.6	57.9	63.4	97.5	87.5	81.8	75.0	83.8	
BLIP CapFilt-L 129M	129M	81.2	38.8	61.1	64.1	53.6	66.8	97.5	87.5	90.0	78.6	84.2	

在标准的图文检索任务（COCO和Flickr30k数据集）上，BLIP全面超越了以往的模型。特别是在使用了CapFilt清洗的海量数据（129M）预训练后，性能优势巨大，树立了新的行业标杆。

不仅仅是预训练：强大的下游任务适应性



强大的预训练为基础，BLIP只需进行少量微调（fine-tuning），就能在广泛的视觉语言下游任务中取得优异表现，展示了其作为基础模型的巨大潜力。

深度总结：BLIP的核心贡献

统一的模型架构
(Unified Model Architecture)



MED框架灵活支持理解、
匹配、生成三大任务。

创新的数据策略
(Innovative Data Strategy)



CapFilt机制有效利用并清
洗了海量网络噪音数据。

卓越的性能表现
(State-of-the-Art Performance)



在多项视觉语言任务上
树立了新的性能标杆。

最后的思考...

「AI的未来，不仅在于更大的模型，更在于更智能的数据。BLIP展示了模型与数据如何相互成就的经典范例。」