



AI大模型思维链原理

从CoT到AOT，解锁大模型的推理潜力

本次分享大纲



01.

思维链基础：
从算术误区到原理觉醒



02.

链式进阶：
CoT与自一致性采样



03.

树形探索：
ToT的分支评估机制



04.

算法化整合：
AOT的一次性全景注入



05.

全景总结：
选型指南与未来展望

网球与苹果计算：错误为何发生？

✅ 成功案例（网球问题）



问题：初始5个网球，购买2盒每盒3个。总数？

模型输出： $5 + 2 * 3 = 11$

分析：模型正确，因提示隐含了推理过程。

❌ 失败案例（苹果问题）




问题：初始23个苹果，用掉20个再买6个。总数？

模型输出（错误）：27

分析：失败根源：提示词仅给答案，未暴露思考过程。

核心观点：必须把完整的计算过程写进提示词，才能引导模型正确推理。

思维链本质：激发既有能力，而非提升



大模型（游戏开发者）

决定了游戏世界的基础规则与能力上限。模型本身的能力是天花板。



提示词编写者（职业玩家）

通过精妙策略（提示词）挖掘并发挥模型的既有潜力。

结论：若模型本身能力不足，再精巧的提示词也难以奏效。
模型能力第一，提示技巧第二。

CoT: 把大脑草稿写进提示

"跳跃式"错误

问题：用 8, 6, 4 算 24

模型错误尝试：

` $9 \times 2 = 18$, $4 \times 1 = 4$,
 $18 + 4 = 22 \dots$ ` (卡住) ❌

根源：缺乏清晰的策略，易在换数字时失败。

分步推理



CoT提示范例：

1. 首先，我注意到 $8 - 6 = 2$
2. 这样，我就剩下了数字 4 和 2
3. 然后，我计算 $4 + 2 = 6$
4. 最后，我用 $6 \times 4 = 24$




效果：

步骤越详细，模型越能模仿人类解题节奏，输出稳定正确答案。

CoT-SC: 用“投票”降低统计误差

The Problem: 单一的思维链也可能出错。



1. 生成多个推理链

对同一问题，让模型独立生成3条以上不同的推理路径。



2. 投票选择最一致答案

通过“多数投票”机制选择出现最频繁的答案。



3. 提升可靠性

有效减少偶发错误，但需承担多次调用的计算成本。


Analogy: 类似于机器学习中的随机森林 (Random Forest)，通过集成策略提升最终结果的可靠性。CoT-SC是典型的“效果-成本”权衡。

思维的跃迁：从“链”到“树” (Tree of Thought, ToT)



CoT (思维链)

- **模式：**单线推理，一条路走到底。
- **缺点：**一步错，步步错。



ToT (思维树)

- **模式：**模拟树状搜索，引入“试错-回溯”机制。
- **优点：**允许探索、评估和选择最优分支，避免满盘皆输。

ToT 的工作引擎：建议（Proposer）与评估（Evaluator）

Proposer Prompt（建议提示词）

Source Han Sans CN

Source Code Pro

核心指令："请对数字 [9, 4, 2, 1] 提出3-5种不同的、合法的下一步算术操作..."

模型输出示例：

Source Code Pro

1. $9 + 4 = 13$ （剩余：13, 2, 1）
2. $9 - 4 = 5$ （剩余：5, 2, 1）
3. $4 * 2 = 8$ （剩余：9, 8, 1）

Evaluator Prompt（价值提示词）

Source Han Sans CN

Source Code Pro

核心指令："请评估以下操作，判断它们能否让结果更接近24，并给出1-10的评分..."

模型输出示例：


ZCOOL KuaiLe

` $4 * 2 = 8$ `：**8分**。理由：9和8与24的差值较小...

` $9 - 4 = 5$ `：**4分**。理由：5, 2, 1组合距离24较远...

更高效的探索：算法化整合 (AOT)

ToT: 树状搜索



方法：逐步展开，多轮调用，允许回溯。

特点：深度探索，过程复杂，成本高。

AOT: 平行列表



方法：一次性生成所有方案，横向比较，减少调用。

特点：广度优先，一次决策，无回溯。

AOT 将“树”压成“平行列表”，要求模型具备更强的信息整合与批判能力。

AOT 提示词构造：组织多方案草稿

Part 1: 指令生成多方案

Prompt Example: "请为数字 [9, 4, 2, 1] 生成3种不同的24点解法，每条用编号+分步等式呈现。"

Part 2: 指令审视与决策

Prompt Example: "现在，请审视以上方案，选择最可靠的一个作为最终答案，并给出理由。"




注意事项：

- 提示词长度随方案数线性增长，可能超过2k tokens。
- 需关注模型的上下文窗口限制和API费用。
- 需在提示词中明确对方案格式和数量的要求。

四条技术路线对比速览表


方法	推理方式	调用次数	模型能力要求	成本	适用场景
CoT	单线推理	1次	基础指令跟随	低	简单推理，成本敏感
CoT-SC	多条单线投票	3-5次	基础指令跟随	中	中等难度，平衡效果与成本
ToT	树状搜索	多轮 (N*M)	高 (生成/评估/批判)	高	高难度，高可靠性要求
AOT	平行方案比较	1-2次	高 (整合/批判)	中	中等难度，追求效率

模型基线优先：先选型，再提示



1. 优先升级模型

当基线低于50%，即使使用ToT也难以突破80%。预算应优先用于选择更强的模型。



2. 再用提示技巧

基线达70%的模型，用简单CoT即可超90%。提示技巧用于榨干模型最后一滴性能。

避免反向优化：模型能力 > 提示技巧

当前挑战与未来方向：从“手艺”走向“工程”

当前痛点



高昂的试错成本

平均每个任务需5-8轮实验才能稳定。



低下的迁移性

换模型后常需重调甚至重写。



未来方向



1. 自动化提示工程

结合强化学习自动搜索最优提示结构。



2. 模型自我修正

让模型在推理中动态调用外部工具或反馈环境，实现自我校正。



3. 能力蒸馏


将大模型思维链能力迁移至小模型。

核心要点总结



1. 思维链是“激发”而非“创造”

CoT等技术的核心是引导模型使用其**既有的推理能力**。强大的基础模型是所有高级技巧的前提。



2. 演进路径是用成本换取复杂度

技术的演进路径 (CoT -> ToT -> AOT) 是用不同的**实施与计算成本**，换取解决更**复杂问题**的能力。



3. AOT的迁移性警示

像AOT这样的长提示技巧在GPT-4等强模型上效果显著，但在小模型上可能因无法处理长上下文而导致性能下降。切勿迷信“长即强”。