

多模态Vision Transformer




当Transformer睁开双眼：深入解析ViT架构，开启视觉与语言融合的新纪元

探索之旅：从像素到语义



视觉的十字路口

两种截然不同的技术哲学——CNN与Transformer的对决。



ViT核心架构解构

深入内部，分步拆解ViT如何将图像转化为Transformer能理解的序列。



实验与洞察

用数据说话，看ViT的性能表现，并探索它究竟学到了什么。




总结与展望

回顾ViT的核心贡献，以及它如何为多模态的未来奠定基石。


两条道路：CNN与Transformer的设计哲学

归纳偏置 (Inductive Bias)



- 局部性 (Locality)：卷积核只处理局部区域。
- 平移不变性 (Translation Invariance)：目标在图像中的位置不影响识别。
- 这是为模型注入的“先验经验”。

全局上下文 (Global Context)





- 最初设计用于处理序列数据（如文本）。
- 归纳偏置弱，更依赖从海量数据中学习模式。



一个为序列而生的王者，能否征服由像素构成的世界？

核心思想：像处理句子一样处理图像



图像 (Image) -> 句子 (Sentence)
图像块 (Patch) -> 单词 (Word/Token)

ViT的突破性贡献在于，它证明了我们可以不依赖卷积，而是将计算机视觉问题（CV）转化为自然语言处理问题（NLP）来解决。

第1步：从像素到向量 (Patch Embedding)

输入图像




$H \times W \times C$
(例如: $224 \times 224 \times 3$)

切分成块 (Patches)



N 个 $P \times P$ 的图像块。
 $N = (H * W) / (P * P)$
(例如: $\frac{224 * 224}{16 * 16} = 196$ 个图像块)


展平与线性投射




展平 (Flatten): $P \times P \times C \rightarrow 1 \times (P * P * C)$
(例如: $16 * 16 * 3 = 768$)

线性投射 (Linear Projection): $(P * P * C) \rightarrow D$
(例如: $768 \rightarrow 768$), 其中 D 是Transformer模型的隐藏层维度 (Hidden Size)。

第2步：注入上下文信息




第3步：进入核心 – 标准Transformer编码器




ViT的优雅之处在于：对输入图像进行巧妙的序列化处理后，可以直接利用NLP领域中成熟的Transformer编码器结构，几乎无需任何修改。这验证了Transformer架构的通用性和强大能力。

架构蓝图：ViT完整流程




性能表现：数据规模决定模型上限




ViT学到了什么？深入注意力机制

位置编码的相似性



图中呈现出明显的行列结构，并且同一行/列的块之间相似度更高。这表明模型在没有显式指导的情况下，自主学会了图像的2D空间结构和相对位置关系。

平均注意力距离



在**底层网络**，注意力头倾向于关注距离较近的像素，其行为类似于CNN的局部卷积。在**高层网络**，注意力距离显著增加，表明模型开始关注全局的、语义相关的区域。

两种设计哲学的对决

特性 (Feature)	Vision Transformer (ViT)	卷积神经网络 (CNN)
核心机制 (Core Mechanism)	自注意力 (Self-Attention)	卷积 (Convolution)
感受野 (Receptive Field)	全局 (Global) - 每个块都能关注到所有其他块	局部 (Local) - 逐层扩大
归纳偏置 (Inductive Bias)	弱 (Weak) - 仅在切块时引入了少量局部性	强 (Strong) - 内置局部性、平移不变性
数据依赖 (Data Dependency)	极高 (Very High)	较低 (Lower)
适用场景 (Best For)	超大规模数据集预训练	中小规模数据集，或作为混合模型的一部分

开启多模态之门



ViT的成功，历史性地统一了视觉和语言任务的建模范式。通过将图像“翻译”成Transformer能理解的序列，我们现在可以用同一个强大的架构同时“阅读”文本和“观看”图像。

未来的基石

CLIP



DALL·E 2



Flamingo

核心要点回顾

范式转变

ViT将图像成功序列化，证明了Transformer架构无需卷积也能主宰视觉领域，打破了CNN长达十年的统治。

架构核心

“图像块=单词”是其灵魂思想。模型主体几乎是原封不动的标准Transformer编码器，展现了架构的通用性。

成功的代价

ViT的强大威力建立在海量数据预训练之上。其对数据和算力的极高要求是应用时的关键考量。

未来的基石

ViT统一了特征提取器，是后续CLIP、DALL-E等众多开创性多模态模型的关键技术基石。

深入探索



原始论文

"An Image is Worth 16x16 Words:
Transformers for Image Recognition at
Scale" (Dosovitskiy et al., 2020)



开源实现


TIMM (PyTorch Image Models)



开源实现



TIMM (PyTorch Image Models)



重要后续工作

DeiT (Data-efficient Image Transformers): 探索如何在更少的数据下有效训练ViT。

Swin Transformer: 引入窗口化和层级化注意力，提升效率和性能，成为后续视觉骨干网络的新标杆。

附录：模型变体与超参数

Model	Layers (L)	Hidden size (D)	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

命名约定

- “ViT-L/16” 指的是 **Large** 版本的ViT，使用“16x16”大小的图像块（Patch Size）。

性能权衡

- 图像块尺寸（Patch Size）是一个关键超参数。
 - ↓ **更小的Patch Size**：序列长度更长，计算复杂度更高，但理论上能捕捉更精细的细节，性能更好。
 - ↑ **更大的Patch Size**：序列长度更短，计算效率更高，但可能会丢失细节信息。