

AI大模型技术解析

从基础架构到核心机制



我们今天的探索之旅




什么是大模型？不止于“大”

核心定义

大模型是人工智能领域的核心技术，基于海量数据训练，具备强大的模式识别与生成能力。

关键价值

它们已成为自然语言处理、计算机视觉等多领域的基础架构，推动AI应用从专用向通用智能演进。



大模型家族的三大分支



大语言模型 (LLM)

以文本为核心输入，基于Transformer架构构建基础模型，专注于语言理解与生成。



多模态大模型 (Multimodal)

支持视频、文本、图像等多元数据输入，实现跨模态信息融合与处理。




增强型大模型 (Augmented)

集成深度推理机制，具备“知识领悟”能力，可在复杂任务中展现类人思考过程（例如，调用外部API查询实时天气）。


模型的生命周期：“学习”与“应用”

训练阶段 (Training Phase)



- 目标：学习知识，生成模型权重参数。
- 过程：依托大规模GPU集群，对海量语料库进行算法训练。
- 类比：像一名学生，通过阅读海量书籍来学习全世界的知识，形成“静态权重”。

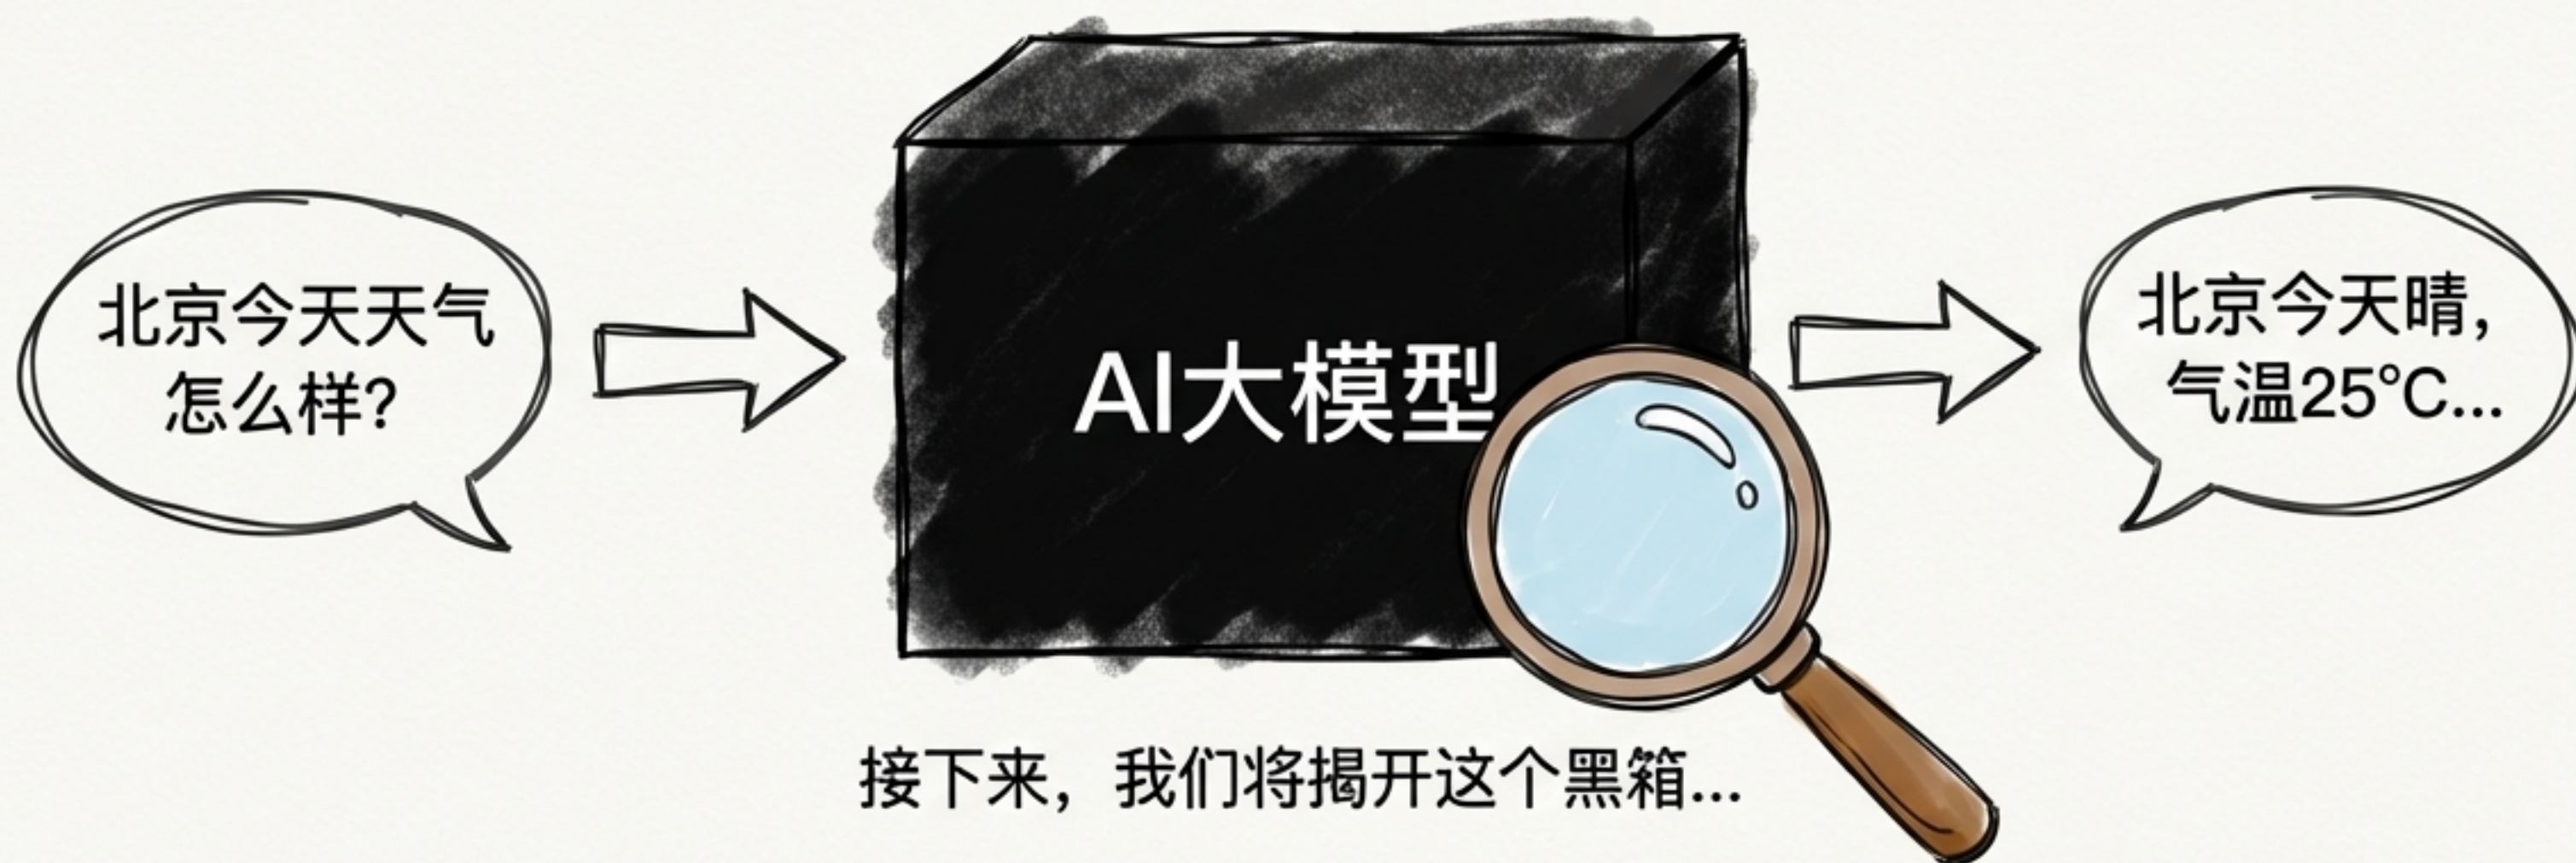
推理阶段 (Inference Phase)



- 目标：应用知识，生成个性化输出。
- 过程：用户通过交互界面输入prompt，模型调用预训练权重进行计算。
- 类比：学生毕业后，运用所学知识解答用户提出的各种问题，展现“动态智能”。

旅程起点：当静态权重遇上动态智能


推理机制是大型模型实现智能交互的核心流程。它通过输入解析、向量转换、深度计算与输出优化，将用户需求转化为精准响应。



关键定义：推理是从“静态权重”到“动态智能”的关键桥梁。

旅程第一站：将语言拆解为模型的“积木块”（Token化）

Token是模型能够理解的最小语义单元，可以是一个词、一个字，甚至是标点符号。用户输入的prompt首先需要被拆解为离散的token单元。




关键数据点

- 中文示例：“我爱你，我们都是中国人”（12个字符）→ 8个Tokens
- 英文示例：“many words indivisible123 456” → 复合词拆分，数字独立成token。

旅程第二站：从“积木块”到“语义坐标”（向量化）

通过Embedding算法，将每个离散的Token映射到一个高维度的数学向量（一长串数字）。

核心意义：向量在空间中的位置和方向代表了Token的语义信息。意思相近的Token，其向量在空间中也更接近。



深度解析：Embedding的维度与规模

向量维度差异


维度越高，能编码的语义信息越丰富。

- DeepSeek-V3: **7168维**
- LLaMA-7B: **4096维**

矩阵规模

Embedding矩阵 = 词表大小 × 向量维度。
这是模型参数的重要组成部分。

- DeepSeek-V3词表: **129,280** 种token类型
- DeepSeek-V3 Embedding矩阵: $129,280 \times 7,168$, 存储约 **671GB** 参数。




旅程第三站：模型的“思考核心”（Transformer层处理）

核心功能

向量流经多层复杂的Transformer网络，进行深度计算，最终输出一个词汇概率分布。

魔法所在 - 注意力机制 (Attention Mechanism)

模型会计算输入序列中每个Token对其他Token的“重要性”或“关联度”，并据此调整信息权重，从而真正理解上下文。




旅程第四站：预测与采样（输出采样）


- 过程：经过Transformer处理后，模型会输出一个覆盖整个词汇表的概率分布，预测下一个最可能的Token。
- 关键参数 - 温度（Temperature）：通过温度参数控制随机性，而非总是选择概率最高的词。

严谨

低温（Low Temperature）
→ 固定输出，结果更严谨、保守。




严谨



奔放


奔放

高温（High Temperature）
→ 多样化结果，输出更具创意、随机。




旅程终点站：周而复始，编织成句（长度扩展）

- **核心机制：**模型将上一步生成的Token，作为新的输入，与原始Prompt一起，再次重复整个推理旅程，以生成再下一个Token。
- **停止条件：**这个循环不断进行，直直到触发停止条件，如生成了结束符[EOF]，或达到了最大token限制。




融会贯通：从Prompt到答案的完整旅程




静态权重（训练所得）+ 动态计算（推理过程）= 动态智能（生成内容）

核心技术要点回顾



模块化流程：大模型推理是一个高度模块化的流程（分词->向量->计算->生成）。



向量是核心：语言的数学表示（向量）是AI理解和处理自然语言的基础。




Transformer是引擎：注意力机制是Transformer架构的灵魂，赋予模型强大的上下文理解能力。



参数可调控：我们可以通过温度(Temperature)等参数，影响模型的输出风格，实现从精确到创意的平衡。

规模与算法的交响



规模

Noto Sans SC



算法

Noto Sans SC

AI大模型的强大能力，源于海量数据和巨量参数所代表的“暴力美学”，也同样源于其内部精巧、高效的核心算法机制。理解这两者的结合，是掌握未来AI技术的关键。