



AI大模型推理与训练详解

一份给工程师的AI工厂深度导览图



我们从“成品”看起：AI如何与我们对话？



核心能力：等长序列生成。你输入一句话，我生成一句对应的答复，像对话一样自然。

导览路线图：探索AI工厂的四大核心车间


01



推理机制：从自回归到高效生成

(探究成品的“思考”与“组装”过程)


02



数据处理：流水线优化与分词精进

(学习如何将海量文本转化为可用“零件”)


03



采样策略：滑动窗口提升效率

(揭秘如何高效生成海量训练“半成品”)

04




架构设计：模型内部结构探秘

(解读AI“引擎”的内部架构蓝图)

推理机制 I：像老式打字机一样，一次“组装”一个词

核心概念：自回归 (Autoregressive)




取末尾词 → 拼回输入 → 继续预测

结束标志 (End Token)：
生成过程并非无限循环。当模型预测出一个特殊的刹车键 (End Token) 时，推理便会停止。

两种生产模式：推理 vs. 训练


推理 (Inference)



模型基于自己之前的输出进行下一步预测。

闭卷考试，只能依靠自己。

训练 (Training)




模型直接获得**标准答案**作为下一步输入，无需“自己猜”。
这种方法称为 **Teacher Forcing**。

开卷考试，照抄标准答案。

→ **目的：**避免模型在训练早期因一个错误导致后续预测全盘皆错（误差累积）。

数据处理 I：将文本拆解为标准“零件”（Tokenization）

- 核心问题：计算机无法直接理解连续的文本。
- 解决方案：将文本切分为独立的、可处理的单元，即 **Token**（词元）。




就像把乐高积木拆散，每个小块（Token）都可以被模型重新组合和理解。

数据处理 II: 为每个“零件”分配唯一编号 (Token-to-ID)

构建一个词汇表 (Vocabulary), 为每个唯一的 Token 分配一个数字 ID, 方便模型进行数学处理。


编码 (Encoding) : Token $\rightarrow$ ID

解码 (Decoding) : ID $\rightarrow$ Token




数据处理 III：用BPE算法智能处理未知“零件”

面临的痛点：未登录词（Out-of-Vocabulary, OOV）




解决方案：字节对编码（Byte Pair Encoding, BPE）



保留词根语义

如“im”表示否定，BPE可以保留这些有意义的子词单元。




灵活组装新词

像拼积木一样，用已知的基础块拼出未知的新造型。

采样策略：用“滑动窗口”从长文本中批量裁剪训练样本

目标：从原始文本中高效地生成大量的（输入，目标）配对，用于模型训练。

今天天气真不错适合出去走走




⚙️ 方法：定长窗口切片。设定一个上下文长度（如3个Token），将文本切分为“输入”和“目标”的配对。


效率调优：步幅(Stride)与批量(Batch Size)的权衡

这是速度、效果和硬件资源之间的权衡。

参数一：步幅 (Stride)




参数二：批量大小 (Batch Size)



Setting 1 (Small Batch)
训练慢, 但内存占用小。

Setting 2 (Large Batch)
并行计算显著提升训练速度,
平均损失值更稳定。




权衡：意味着更高的内存需求。

模型架构：AI工厂的三层核心骨架





嵌入层
(Embedding Layer)

文字到向量的翻译官。将离散的Token ID映射为包含语义信息的连续向量。



Transformer层


特征提取的核心引擎。通过自注意力机制理解上下文，捕捉词与词之间的关系。



输出层
(Output Layer)


全连接网络生成词概率。将特征映射为词汇表中每个词的概率分布。

深入引擎室：理解上下文的Transformer层



核心功能：捕捉文本中任意两个词之间的全局依赖关系。无论相隔多远，模型都能深入理解上下文，提取出高级语义特征。

完整蓝图：从用户输入到AI输出的全过程



核心总结：构建AI工厂的四大支柱

推理 (Inference)




核心是 **自回归**
(逐词生成, 周而复始)

数据 (Data)




核心是 **分词**
(文本结构化, 万物皆可量化)

采样 (Sampling)



核心是 **滑动窗口**
(海量样本, 高效生成)

架构 (Architecture)



核心是 **Transformer**
(上下文理解, 关系捕捉)


蓝图之外：工程师的进阶之路

我们今天探索的是预训练大模型的基础。要将其打造为强大的生产力工具，还需要更多进阶工艺。




模型微调与对齐 (Fine-tuning & RLHF)

如何让模型听懂“人话”，变得更有用、更安全。




量化与推理优化 (Quantization & Optimization)

如何让庞大的模型跑得更快、成本更低。



高级架构 (Advanced Architectures)

探索更高效的模型结构，如 MoE (Mixture of Experts)。



分布式训练 (Distributed Training)

如何用成千上万的机器协同训练一个巨型模型。