

AI大模型企业落地实战指南

从基础部署到高级优化的完整路线图



本次分享大纲：您的企业AI落地征途



为什么不能直接用公有大模型处理核心业务？

通用大模型最大的问题不是能力不够强，而是“不懂你”。
它不知道你的行业术语、内部流程和合规红线。

通用模型



企业现实



第一道门槛：私有化部署


数据不出内网，是合规与安全的生命线。这是后续一切定制化开发的基础。



- ✓ 避免核心数据（客户名称、项目预算、合作意向）泄露。
- ✓ 满足金融、医疗、政务等强监管行业的合规要求。
- ✓ 拥有一个能改、能调、能控的模型实例。

稳妥落地：私有化部署四步法

90%的私有化失败 源于环境配置问题，而非模型本身。遵循此方法可规避常见陷阱。



速成篇：如何让新员工（AI）快速上手？

无需昂贵的“再培训”，用“有效沟通”（提示工程）和“外部资料”（RAG）就能解决80%的问题。



技巧一：提示工程 - 把“问对问题”变成一门科学

好的提示词是“磨”出来的，像调试代码一样不断测试和优化。




角色扮演 (Role-Playing)

示例：“你是一位精通制造业的资深法务...”




示例驱动 (Few-Shot Learning)

示例：“请模仿这个案例的风格和结构...”



思维链 (Chain of Thought)

示例：“先分析风险，再给出建议，最后总结条款...”




格式模板 (Format Templating)

示例：“请以Markdown表格或JSON格式输出...”

技巧二：RAG - 给大模型一个外挂知识库

RAG（检索增强生成）让模型无需重新训练，就能掌握最新的内部知识（产品手册、制度文件、历史合同等）。



1. 文档载入 (Ingest)

Icons of PDF and Word documents flowing into a funnel.

2. 文本切片 (Chunk)

A document icon being sliced into smaller horizontal pieces by a dotted line with a scissors icon.

3. 向量化 (Embed)

The text pieces are shown transforming into abstract numerical vector representations (e.g., small bar charts or arrays of numbers). Arrow labeled 'Embedding'.

4. 检索 (Retrieve)

A large database cylinder icon labeled "向量数据库". A user query, represented by a magnifying glass icon, is shown pulling the most relevant vector pieces from the database.

5. 生成 (Generate)

The user query and the retrieved knowledge chunks are shown being fed into an LLM (brain icon), which then outputs a final, coherent answer in a speech bubble.

Answer:
根据最新产品手册，功能X的使用步骤是... ✓

RAG的三大核心业务优势



更新快 (Fast Updates)

说明：知识库更新，AI能力
即时同步。



成本低 (Low Cost)

说明：无需重新训练模型，
节省大量算力和时间。



可追溯 (Traceable)


说明：AI的回答能明确引用的
原文出处，便于审计和纠错。

进阶篇：Agent - 让AI成为“办事员”


Agent不仅能回答问题，更能主动调用工具、执行任务、完成业务闭环。



知道 (Knowing)




能力进化
(Capability Evolution)



做到 (Doing)

单Agent workflow: AI助手如何帮你订午餐


Agent的核心是把企业系统能力（HR、CRM、支付）封装成AI能调用的工具（API）。



多Agent协作：自动化复杂的合同审批流程


就像搭积木，每个Agent负责自己最擅长的事情，组合起来就能处理复杂流程。

关键是“分工明确 + 通信顺畅”。



精通篇：当效果卡在85%，如何冲击95%？

核心思意：当外部“输血”（提示工程、RAG）不够时，就需要对模型本身进行“基因改造”（微调、蒸馏）。




触发微调的三个量化信号

- 1. **提示词过长**：超过8000个Token，导致模型理解力分散。
- 2. **RAG召回无效**：检索出的知识与问题不相关，说明模型看不懂业务语言。
- 3. **核心业务指标不达标**：例如，合同生成准确率卡在85%，而业务要求是95%。

高效微调：用LoRA给模型“穿上”专业外衣


LoRA这类高效微调方法，只训练模型一小部分新增参数，就能达到接近全量微调的效果，同时大幅降低成本和时间。



关键数据：一个7B模型使用4块A100显卡，3天左右即可完成LoRA微调。

模型蒸馏：让“大象”学会“兔子”的敏捷

核心思想：模型蒸馏是在效率和效果之间找到最佳平衡点，让AI跑得更快、更省资源。



落地场景1：高并发场景

- 银行柜台系统，每秒处理上百次查询。

落地场景2：边缘部署

- 在手机端实现离线AI助手。


人才篇：AI重塑岗位，而非取代人类

成功的AI落地，技术和人同样重要。企业需要建立横向的“AI能力中心”来统一管理和培养人才。



核心新角色：大模型应用开发工程师

这不是传统的算法工程师，也不是纯粹的业务人员，而是一个“左手技术，右手业务”的桥梁型人才。



既能在技术群里讨论CUDA版本，也要能在业务会上解释方案如何节省人力成本。

如何系统性地打造企业AI团队？

采用“三步走”战略，系统性地解决人才缺口问题。



内部转岗 (Internal Transfer)

说明：选择熟悉公司系统的技术骨干（如后端、数据工程师）进行3周左右的集中培训，见效快、成本低。



校园招聘 (Campus Recruiting)


说明：与高校合作开设课题，锁定优秀应届生，作为长期人才储备。



外部合作 (External Collaboration)

说明：与云厂商、开源社区共建实验室，共享资源，共克难题，尤其适合中小企业。

总结：企业大模型落地的螺旋上升之路



谢谢 & Q&A

不要追求一步到位，
而是先跑起来，
再持续优化。

企业大模型落地不是非此即彼的选择，而是按需组合的工具箱。

Noto Sans SC Regular

