



知识图谱嵌入技术

从符号世界到向量空间的桥梁



学习大纲：一步步揭开知识图谱嵌入的奥秘



第一章：从图到向量

“为什么需要嵌入？将知识转化为**机器可理解的语言**。”




第二章：数据准备与样本构造

“如何为模型“备课”？构建**训练、验证与测试集**。”



第三章：拆解完整训练流程

“模型是如何学习的？从随机初始化到**智能收敛**。”



第四章：主流模型变体对比

“如何选择更优的方法？**平移距离** vs. **语义匹配**。”



总结与应用

“技术价值与**真实世界应用**。”


第一章：从图到向量

知识的本质：三元组 (Triples)



- 现实世界中的事实都可以被拆解为（头实体，关系，尾实体）的结构。
- 例如：(张三, 仇人, 李四)
- 这种结构简单、不丢失信息，是后续数学处理的基础。

嵌入的核心思想：赋予坐标




- 我们为每个实体和关系，在“语义空间”中分配一个数学坐标（向量）。
- 目标：让语义上相近的概念，在空间中的距离也相近。
- 例如：vector(猫) 和 vector(狗) 的距离很近，而 vector(电脑) 和 vector(电脑) 的距离很远。
- 好处：复杂的图结构问题，转化为高效的向量计算问题。

第二章：为模型“备课”

第一步：划分数据集

- “将所有三元组随机打乱，并按比例切分，以评估模型的“举一反三”能力。”



- **关键点：**切分过程中必须保证实体和关系的词汇表一致，否则就像考试题目用了学生没学过的词。

第二步：构造负样本

“模型不仅要知道什么是“对”的，还要知道什么是“错”的，才能学会判断。”



正样本 (Positive) :

(张三, 仇人, 李四)

知识图谱中真实存在的事实。



负样本 (Negative) :

(张三, 仇人, 王五)


我们人为制造的、大概率不成立的“假”事实。

核心假设：局部封闭世界假设 (Local Closed World Assumption)

- “如果一个三元组不在知识图谱中，那么它大概率是假的。”
- * “现实启发：一个人的仇人一般不会太多。如果(张三, 仇人, 李四)是真的，那么随机替换李四后，新的三元组大概率是假的。”*

如何巧妙地“制造”假象？

我们采用一种简单有效的策略：**随机替换**。




操作流程：

1. 选取一个正样本，如` (张三, 仇人, 李四) `。
2. 随机选择一个实体（如 "王五" ）来替换头实体或尾实体。
3. 生成负样本：` (张三, 仇人, 王五) `。
4. ****关键一步：过滤 (Filtering)****。检查新生成的负样本是否恰好也存在于原始知识图谱中。如果是，则丢弃，避免模型混淆。

第三章：模型是如何学习的？

起点：随机初始化

“在训练开始前，每个实体和关系都被赋予一个完全随机的向量。它们就像在语义空间中被随机撒下的点，没有任何意义。”



核心思想：平移不变性（TransE模型）

“训练的目标，是让向量的位置变得有意义。我们基于一个核心假设：”

$$### \textbf{**} h + r \approx t \textbf{**}$$


****直观理解****：“关系”被看作是一种从“头实体”到“尾实体”的平移操作。

$$\text{`vector(张三) + vector(仇人) } \approx \text{vector(李四)}`}$$

训练目标：拉近真的，推远假的

模型通过一个“损失函数” (Loss Function) 来指导学习。这个函数的目标是：


正样本 (Positive Sample)



我们希望 $h + r$ 与 t 尽可能接近。

目标：最小化距离 $\|h + r - t\|$ 。

负样本 (Negative Sample)



我们希望 $h + r$ 与 t' 尽可能远离。

目标：最大化距离 $\|h + r - t'\|$ 。

“训练过程就是不断调整所有向量，使得真实关系的距离越来越小，虚假关系的距离越来越大。”


训练循环：千锤百炼，铸就有意义的向量

“训练是一个从无序到有序，不断迭代、优化向量的过程。”



批量采样 (Batch Sampling)

从训练集中随机抽取一小批正样本和对应的负样本。



计算损失 (Calculate Loss)

根据 $h + r \approx t$ 的原则，计算这批样本的总损失。



更新向量

反向传播 (Backpropagation)

使用梯度下降等优化算法，根据损失值，微调所有涉及到的向量，让它们朝“正确”的方向移动一点点。




循环迭代 (Repeat)

重复以上步骤，直到模型在验证集上表现最佳（通过**早停机制** Early Stopping 防止过拟合）。


第四章：主流模型变体对比

“ $h + r \approx t$ ”的思想很棒，但也存在局限（如无法很好处理一对多关系）。因此，研究者们提出了更强大的模型，主要分为两大流派。



平移距离模型 (Translational Distance Models)

- **核心思想**：“将关系建模为向量空间中的**平移操作**。”
- **优点**：“**模型简单，计算高效**。”
- **代表模型**：“TransE, TransH, TransR”




**语义匹配模型 (Semantic Matching Models) **

- **核心思想**：“通过**乘法运算**来衡量实体与关系之间的语义匹配程度。”
- **优点**：“能更好地捕捉复杂关系（对称、反对称等）。”
- **代表模型**：“DistMult, RESCAL”

平移模型的进化之路


1. TransE: 经典起点



所有实体和关系在同一空间

问题: 难以处理一个实体有多个关系对象的情况 (1-N), 例如一个国家有多个城市。


2. TransH: 引入关系超平面



投影到关系超平面

改进: 每个关系都有一个专属的“超平面”或“跑道”，实体先投影到这个平面上再进行平移，互不干扰。


3. TransR: 引入关系空间



投影到独立关系空间

再进一步: 每个关系不仅有自的空间，还能将头尾实体映射到该空间中运算，好比为每种关系配备了一个“翻译器”。

深度总结：我们的旅程



技术的价值：知识嵌入在真实世界的应用



####**推荐系统 & 搜索**

通过计算**用户**和**物品**向量的**相似度**，实现更精准的个性化推荐。

"买了这个的人也买了..."



####**智能问答 (Q&A) **

在海量知识中进行**多步推理**，找到问题的答案，而不仅仅是关键词匹配。



####**医疗 & 生物信息**

发现药物、基因和疾病之间隐藏的**关联**，加速新药研发。




####**金融反欺诈**

构建用户、账户、交易之间的**关系图谱**，识别异常的交易模式。

最终目标：理解事实之间的深层联系

知识图谱嵌入技术不仅是数据存储的一种方式，更是连接**符号世界**与**数字世界**的桥梁。



它让机器不仅能**记住**事实，更能**理解**事实之间的联系，为更智能的应用打下坚实的基础。