


DeepSeek-R1 微调实战

零成本打造垂直领域专属专家模型




AI 微调技术路线图：从入门到精通

1

核心概念


理解微调与 LoRA 的"便利贴"原理



2

环境准备

ModelScope 免费 GPU 环境搭建



3

七步通关

从数据清洗到模型训练的全流程拆解



4


价值展望

2026 年的职场竞争力分析



为什么要掌握微调？

调用 API / 通才



- 数据出域（隐私风险）
- 回复通用（缺乏业务深度）
- 可替代性强

本地微调 / 专才



- 数据私有化（绝对安全）
- 懂行业黑话（销售/法律/医疗）
- 稀缺职场技能

2026 年的企业不缺会调 API 的人，缺的是能把开源模型练成懂业务的‘私有专家’的人。

微调的本质：从“本科生”到“行业专家”

Stage 1

DeepSeek 基座模型



懂物理、历史、代码，
但不懂你的公司业务。

Stage 2

微调训练 (Training)



Stage 3


垂直领域模型



懂客服话术、懂法律条文、
懂内部代码规范。


2026 年的企业不缺会调 API 的人，缺的是能把开源模型练成懂业务的‘私有专家’的人。

LoRA 技术：给大模型贴“便利贴”



考试时，模型既看原来的书，也看旁边的便利贴——这就是高效微调的原理。

LoRA 的三大核心优势



省显存 (Low VRAM)

显存占用仅为原来的 1/3，
免费云端显卡也能跑。



速度快 (High Speed)

喝杯咖啡的功夫（几十分钟）即可完成训练。



效果好 (High Performance)

在垂直领域效果完全不输
全量微调。

零成本实战工具箱



环境搭建：获取免费算力



不用几千块租服务器，也
不用烧自己的笔记本显卡。
直接使用云端免费资源。

必要的依赖库安装


```
!pip install transformers peft bitsandbytes modelscope  
-i https://pypi.tuna.tsinghua.edu.cn/simple
```

JetBrains Mono
One Light


使用国内镜像源，秒速下载



大模型地基




微调管家



显存压缩机

工程规范：良好的文件结构



不要把所有文件堆在根目录。建立清晰的文件夹结构，便于管理模型权重和训练日志。推荐使用 Jupyter Notebook (.ipynb) 进行模块化调试。

步骤一：模型下载与加载


```
from modelscope import snapshot_download
model_dir = snapshot_download('deepseek-ai/DeepSeek-R1-Distill-Qwen-1.5B')

model.to('cuda') # 关键一步
```



必须加载到 GPU！如果是在没有独
显的笔记本 SC 上运行（仅 CPU），请删除
此行， 但速度会极慢。

寻找‘消失’的模型文件




ModelScope 默认将模型下载到隐藏的 `.cache` 目录中。我们需要通过代码或命令行找到它的真实路径。

步骤二：数据格式化




原始问答 (Q&A)



```
{  
  "instruction": "如何练习高音？",  
  "output": "练习高音需要气沉丹田，放松喉头..."  
}
```


JSONL 格式 (每行一个 JSON 对象)

步骤三：训练集与测试集划分




必须保留一部分数据不参与训练，用于验证模型是否真的“学会了”，还是仅仅在“死记硬背”。

步骤四：分词与对齐 (Tokenization)



让所有数据整整齐齐地喂给 GPU。

步骤五：模型量化（Quantization）



模型体积减半，精度损失微乎其微。

步骤六：LoRA 参数配置

```
LoraConfig:{
```

```
  r = 8,
```

Rank: 便利贴的大小


```
  lora_alpha = 16, # 缩放因子 (通常为  $r * 2$ )
```

```
  target_modules = ["q_proj", "v_proj"] # 贴在哪里
```

```
}
```

Parameters define size & scaling of these adapters

Trainable LoRA
Adapters (Small)




Base Model
(Frozen)



仅训练 ~0.06% 的参数，实现四两拨千斤。

理解 Target Modules（目标模块）



我们通常只微调 Query 和 Value 层的投影矩阵，这是性价比最高的选择。

步骤七：设置训练参数




训练轮次（数据少多跑几轮）



⚠ 显存杀手（OOM 时请调小）




混合精度（速度翻倍）



```
per_device_train_batch_size = 4
```


开始训练与监控



Loss 值持续下降说明模型正在学习。如果 Loss 震荡或
不下降，检查数据质量或学习率。