

- 强化学习在自然语言处理下的应用篇

- 一、强化学习基础面

- 1.1 介绍一下强化学习?
 - 1.2 介绍一下强化学习 的状态 (States) 和 观测 (Observations) ?
 - 1.3 强化学习 有哪些 动作空间 (Action Spaces) , 他们之间的区别是什么?
 - 1.4 强化学习 有哪些 Policy策略?
 - 1.5 介绍一下 强化学习 的 轨迹?
 - 1.6 介绍一下 强化学习 的 奖赏函数?
 - 1.7 介绍一下 强化学习问题?

- 二、RL发展路径 (至PPO)

- 2.1 介绍一下 强化学习 中 优化方法 Value-based?
 - 2.2 介绍一下 强化学习 中 贝尔曼方程?
 - 2.3 介绍一下 强化学习 中 优势函数Advantage Functions?

- 致谢

一、强化学习基础面

1.1 介绍一下强化学习?


强化学习 (Reinforcement Learning) 是一种时序决策学习框架, 通过智能体和环境交互

$$a_t = \pi(o_t)$$

得到的奖励

$$r_t = r(o_t, a_t)$$

从而来优化策略 π , 使其能够在环境中自主学习。



1.2 介绍一下强化学习 的状态 (States) 和 观测 (Observations) ?

- 状态 (States) : 对于世界状态的完整描述
- 观测 (Observations) : 对于一个状态的部分描述, 可能会缺失一些信息。当 $O=S$ 时, 称 O 为完美信息/fully observed; $O<S$ 时, 称 O 为非完美信息/partially observed。

1.3 强化学习 有哪些 动作空间 (Action Spaces) , 他们之间的区别是什么?

- 离散动作空间: 当智能体只能采取有限的动作, 如下棋/文本生成
 - 连续动作空间: 当智能体的动作是实数向量, 如机械臂转动角度
- 其区别会影响policy网络的实现方式。

1.4 强化学习 有哪些 Policy策略?

- 确定性策略Deterministic Policy: $a_t = u(s_t)$, 连续动作空间
- 随机性策略Stochastic Policy: $a_t \sim \pi(\cdot|s_t)$, 离散动作空间

1.5 介绍一下 强化学习 的 轨迹?

- 轨迹: 指的是状态和行动的序列

$$\tau = (s_0, a_0, s_1, a_1, \dots)$$

1. 状态转换函数 (transition function) :

$$s_{t+1} \sim P(\cdot|s_t, a_t)$$

1. 初始状态是从初始状态分布中采样的, 一般表示为

$$s_0 \sim \rho(\cdot)$$

1.6 介绍一下 强化学习 的 奖赏函数?

$$r_t \sim R(s_t, a_t, s_{t+1}) / r_t \sim R(s_t, a_t)$$

智能体的目标是最大化**行动轨迹的累计奖励**:

$$R(\tau) = \sum_{t=0}^{\infty} \gamma^t r_t$$

1.7 介绍一下 强化学习问题?

- 核心问题: 选择一种策略从而最大化**预期收益**
1. 假设环境转换和策略都是随机的, 则 T 步行动轨迹概率:

$$P(\tau | \pi) = \rho_0(s_0) \prod_{t=0}^{T-1} P(s_{t+1} | s_t, a_t) \pi(a_t | s_t)$$


1. 预期收益:

$$J(\pi) = \int_{\tau} P(\tau | \pi) R(\tau) = \mathbb{E}_{\tau \sim \pi} [R(\tau)]$$

1. 核心优化问题: 找到最优策略

$$\pi^* = \arg \max_{\pi} J(\pi)$$

二、RL发展路径 (至PPO)



2.1 介绍一下 强化学习 中 优化方法 Value-based?

- value-based: 状态的值 $V(s)$ 或者 状态行动对(state-action pair) 的值 $Q(s,a)$, 作为一种累积奖励的估计, 可以通过最大化值函数来优化得到最优策略

1. 最优值函数 (Optimal Value Function) :

$$V^*(s) = \max_{\pi} \mathbb{E}_{\tau \sim \pi} [R(\tau) \mid s_0 = s]$$

1. 最优动作-值函数 (Optimal Action-Value Function) :

$$Q^*(s, a) = \max_{\pi} \mathbb{E}_{\tau \sim \pi} [R(\tau) \mid s_0 = s, a_0 = a]$$

最优动作:

$$a^*(s) = \arg \max_a Q^*(s, a)$$

1. 两者的关系:

$$V^{\pi}(s) = \mathbb{E}_{a \sim \pi} [Q^{\pi}(s, a)] ; \quad V^*(s) = \max_a Q^*(s, a)$$

2.2 介绍一下 强化学习 中 贝尔曼方程?

- 中心思想: 当前值估计=当前奖励+未来值估计

$$V^{\pi}(s) = \mathbb{E}_{\substack{a \sim \pi \\ s' \sim P}} [r(s, a) + \gamma V^{\pi}(s')]$$

$$Q^{\pi}(s, a) = \mathbb{E}_{s' \sim P} \left[r(s, a) + \gamma \mathbb{E}_{a' \sim \pi} [Q^{\pi}(s', a')] \right]$$

所以, 最优值函数的贝尔曼公式为:

$$V^*(s) = \max_a \mathbb{E}_{s' \sim P} [r(s, a) + \gamma V^*(s')]$$

$$Q^*(s, a) = \mathbb{E}_{s' \sim P} \left[r(s, a) + \gamma \max_{a'} Q^*(s', a') \right]$$

2.3 介绍一下 强化学习 中 优势函数 Advantage Functions?

强化学习中，有时不需要知道一个行动的绝对好坏，而只需要知道它相对于其他action的相对优势。即

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$$